勉強日記

日付

2026年04月05日

学習内容

SageMaker managed warm pools

- **概要**: トレーニングジョブ向けにコンピューティングリソースをウォームアップ状態で保持し、後続ジョ
- **試験ポイント**: インスタンスの起動、AMIの読み込み、コンテナダウンロードなどを省き、連続するト
- **実務での使い方**: 反復的な実験やモデルのハイパーパラメータチューニング（HPO）、CI/CDパイプライ
- **副業での需要**: ★★☆（継続的学習環境などを構築する際、MLエンジニアの待ち時間削減・開発体験向

Managed Spot Training

- **概要**: 未使用のEC2 Spotインスタンスを利用し、トレーニングコストを最大90%削減する機能。
- **試験ポイント**: コスト削減に最も効果的だが、起動時間は短縮されず（むしろ割り当て待ちや中断で延
- **実務での使い方**: 実行時間の制約が緩いモデル学習や、大規模な分散学習時のインフラコストを劇的に
- **副業での需要**: ★★★（AWSコスト最適化案件での需要が非常に高い。チェックポイント機構とセット

SageMaker Training Compiler

- **概要**: PyTorchやTensorFlowのトレーニングスクリプトを最適化し、GPUの利用率を向上してトレーニ
- **試験ポイント**: インフラの起動時間には影響を与えず、あくまでトレーニングの「実行フェーズ」自体の
- **実務での使い方**: 大規模な深層学習モデル（NLPやCV等）の学習において、GPUのアイドル時間を減ら
- **副業での需要**: ★★☆（LLMのファインチューニングなどの高負荷・長時間学習を扱う案件で、学習効

SageMaker distributed data parallelism (SMDDP)

- **概要**: 大規模なデータセットを複数のワーカー（GPU/インスタンス）に分散し、並列でモデルをトレー
- **試験ポイント**: インフラ起動時間の短縮機能は一切なく、複数コンピューティングリソースを活用した
- **実務での使い方**: 単一のインスタンスに収まらないほどの巨大なデータセットを用いて学習を行う際、
- **副業での需要**: ★★☆（大規模データ基盤や企業独自の基盤モデル構築など、高度な分散学習インフラ

Amazon S3のVPCエンドポイント（ゲートウェイ型）

- **概要**: VPC内リソースからインターネットを経由せずにS3へプライベートアクセスを行う機能。ルート
- **試験ポイント**: エンドポイントポリシーで特定バケットやアクションへアクセス制限できる点と、Sage
- **実務での使い方**: 機械学習モデルの学習データやアーティファクトをセキュアな閉域網（NATゲートウ
- **副業での需要**: ★★★（インフラ構築やMLプラットフォーム案件において、金融やヘルスケアなど高セ

SageMaker AIのOPT_OUT_TRACKING環境変数

- **概要**: トレーニングジョブでデフォルト収集されるメタデータ（使用ライブラリの統計情報やエラー等）
- **試験ポイント**: 収集対象は「メタデータのみ（学習データ自体は元から収集されない）」である点と、
- **実務での使い方**: 企業ポリシー等で「利用統計も含めて外部へのいかなるデータ送信も許可されない」
- **副業での需要**: ★☆☆（通常の企業案件では意識されることが少ないが、極めて高いガバナンスが求め

VPCピアリングとS3アクセス

- **概要**: 2つのVPC間をプライベートに接続するVPCピアリングは、リージョナルサービスであるS3に対し
- **試験ポイント**: 「VPCピアリングを経由して別VPCからS3にアクセスする」といった通信経路の誤った
- **実務での使い方**: 複数VPC（システム群）にまたがるネットワークアーキテクチャにおいて、S3への通
- **副業での需要**: ★★☆（AWSネットワークの全体設計やレビューの案件にて、通信可能な経路・不可能

Amazon Comprehendのカスタムモデル

- **概要**: ユーザー固有のドメインや用途に合わせて学習させたNLPモデル機能（エンティティ認識や文書分
- **試験ポイント**: Comprehend内で管理される独自リソースで構成されるため、AWSアカウント間でのモ
  API）」を利用する必要がある点が問われる。
- **実務での使い方**: 医療・法律など専門用語が多い業界や、自社固有の製品名が含まれるテキストデータ
- **副業での需要**: ★★☆（特定のテキストマイニングやレビュー分析案件で、独自辞書に基づくNLP機能を

Amazon Comprehend ImportModel API

- **概要**: 別のAWSアカウントでトレーニングされたComprehendのカスタムモデルを構成情報やメタデー
- **試験ポイント**: DataSyncやVPN等のデータ転送・通信サービスでは代用できない「Comprehend独自リ
- **実務での使い方**: 開発（Dev）アカウントと本番（Prod）アカウントが分かれている構成で、学習済み
- **副業での需要**: ★☆☆（AWSマルチアカウント設計を含めたエンタープライズ向けの堅牢なM-
  LOps基盤構築案件において知っておくべき知識）

AWS DataSync

- **概要**: オンプレミスのストレージとAWS間、あるいはAWSストレージサービス（S3、EFSなど）間で高
- **試験ポイント**: あくまで「ファイルやオブジェクトの転送」に特化しており、ComprehendなどのAIサ
- **実務での使い方**: 大規模な既存オンプレミスデータのAWSへの移行（マイグレーション）や、データレ
- **副業での需要**: ★★★（インフラ移行案件やデータ基盤構築など、オンプレからのデータ集約を含めた

AWS Site-to-Site VPN

- **概要**: オンプレミスのネットワークとAWS VPCを、インターネット経由で安全なIPsec
  VPNトンネルで接続するネットワーク層のサービス。
- **試験ポイント**: ネットワーク接続を確立するインフラサービスであり、「Comprehendのカスタムモデ
- **実務での使い方**: 社内のオンプレミス環境からAWS上の社内向けシステムや閉域リソースへ、安価で安
- **副業での需要**: ★★★（中小規模〜エンタープライズまで、法人向けインフラ構築においてDirect
  Connectよりも手軽にセキュア通信を確保する標準的アプローチとして需要が高い）

SageMaker AIのモデル構築オプション

- **概要**: 用途や要件に応じ、導入の手間の少ない順に「JumpStart（事前学習済）」「組み込みアルゴリ
- **試験ポイント**: 各アプローチの「柔軟性・カスタマイズ性」と「運用コスト（構築・管理の手間）」の
- **実務での使い方**: プロジェクト初期のPoC段階ではJumpStartや組み込みアルゴリズムで素早くベースラ
- **副業での需要**: ★★☆（要件に対してオーバースペックにならない、コストと保守性のバランスが取れた

SageMaker AIスクリプトモードの特徴

- **概要**: AWSが管理するフレームワークコンテナ（PyTorchやscikit-learn等）を利用し、その上で独自の学習スクリプトや依存パッケージ（requirements.txt等）を実行で
- **試験ポイント**: カスタムDockerイメージを自分で構築・管理するインフラ的な労力を省きつつ、オンプ
- **実務での使い方**: ローカルPCや他環境のPythonで開発していた既存の学習スクリプトについて、インフ
- **副業での需要**: ★★★（企業が独自のMLモデルをAWS上のマネージドな学習基盤へ移行・モダナイゼ

SageMaker Canvas・JumpStartの特徴

- **概要**: Canvasはコード不要（ノーコード）でMLモデル構築が可能だがカスタムスクリプトの持ち込み
- **試験ポイント**: Canvasは「プログラミングスキル不要（ビジネスユーザー向け）だがカスタマイズ不可
- **実務での使い方**: Canvasは事業部門（ビジネスサイド）での簡易な予測分析の自主導入に、JumpStart
- **副業での需要**: ★★☆（社内の非エンジニア向けAI利活用推進の支援や、最新の生成AI・OSS基盤モデル

重複データの検出（名寄せ・データ品質管理）

- **概要**: データの分析精度を高めるため、複数属性の類似性を評価して同一エンティティ（重複レコード）
- **試験ポイント**: 構造化/非構造化を問わず複雑なパターンを持つデータの重複検出においては、単なるル FindMatchesなど）」が有効であることが設問の前提になりやすい。
- **実務での使い方**: データレイクやDWHへのデータ取り込み（ETL）パイプラインにおいて、後続の分析
- **副業での需要**: ★★★（データレイク構築等あらゆるデータ系案件において「データの信頼性担保（名

AWS Glue FindMatches変換

- **概要**: AWS GlueのETLジョブ内で提供される、機械学習モデルを利用してデータセット内の「重複レコ
- **試験ポイント**: 「コード開発を最小限にして、大規模データ内の重複（表記ゆれ）をスケーラブルに検
- **実務での使い方**: 顧客名簿や商品マスタなど、複数のシステムから集約されたデータの統合において、
- **副業での需要**: ★★★（データ基盤構築時の正規化プロセスにおいて、カスタム開発を避けマネージド

Amazon Mechanical Turk

- **概要**: 人間の作業者（クラウドワーカー）に対して、画像分類やデータ入力などのタスクを依頼するク
- **試験ポイント**: 選択肢に現れるが、「大量のデータセットの重複検出」には「コストと時間がかかりス
- **実務での使い方**: 機械学習モデル学習時のための教師データ作成（アノテーション作業）や、AIが自信を in-the-loop）」に利用する。
- **副業での需要**: ★☆☆（データセット構築専門のタスクに近く、クラウドインフラやデータエンジニア

Amazon QuickSight ML Insights

- **概要**: BIサービスのAmazon QuickSightにおいて、データの可視化ダッシュボードに異常検出や予測な
- **試験ポイント**: データの可視化や分析には有用だが、「大規模データ内の重複レコード検出」のための
- **実務での使い方**: 経営層やビジネス部門向けダッシュボードに、売上の異常値（スパイク）の自動検出
- **副業での需要**: ★★☆（データ基盤構築からBIダッシュボードまでの構築を一気通貫で請け負う案件に

Amazon SageMaker Data Wrangler

- **概要**: 視覚的なインターフェース（GUI）上で、コーディングなしにデータ前処理や特徴量エンジニア
- **試験ポイント**: 一般的なデータのクリーニングや変換は可能だが、「重複データ自体の高度な検出（Fi
- **実務での使い方**: データサイエンティストがモデル学習準備のための工数を削減するために、Pandas
- **副業での需要**: ★★☆（MLパイプラインの構築において、データ前処理をローコード化・手順化してM

カテゴリカルデータと数値データの変換

- **概要**: 機械学習モデルは計算によって予測を行うため、性別や商品名などの文字列（カテゴリカルデー
- **試験ポイント**: 数学的に処理不可能なカテゴリ変数を扱うための「必須な前処理ステップ」として出題
- **実務での使い方**: 決定木等のツリー系モデル以外のアルゴリズムを利用する際や、モデル精度を最大化
  Engineering）フェーズで、最も初期に行う基本的な変換処理。
- **副業での需要**: ★★★（あらゆるテーブルデータを用いた機械学習の予測構築案件で必ず発生する作業

Amazon SageMaker Data Wrangler（前処理用途）

- **概要**: 視覚的なGUIでデータのフローを構築し、250以上の組み込み変換機能を使って前処理やカテゴ
- **試験ポイント**: 「運用オーバーヘッドを削減する」「コーディングを減らして変換結果を即座に確認する
- **実務での使い方**: データサイエンティストが探索的データ分析（EDA）を実施しながら、ワンホットエ
- **副業での需要**: ★★☆（データ準備のコードをフルスクラッチで書くのではなく、Wranglerを用いて手

AWS Glue（前処理での利用）

- **概要**: 大規模なデータの抽出・変換・ロード（ETL）を実行するフルマネージドサービスで、Pythonや
- **試験ポイント**: 試験の選択肢にはあがるが、「データ変換ロジックを手動でコーディングする必要があ
- **実務での使い方**: 軽量な特徴量エンジニアリング用ではなく、データレイクに溜まったテラバイト級の
- **副業での需要**: ★★★（データエンジニアリング案件としてDWHおよびデータレイク構築基盤のコア技

データ前処理の運用オーバーヘッド

- **概要**: 機械学習システムの構築や運用において、データ変換や前処理を維持・管理するために発生する
- **試験ポイント**: 設問シナリオにおいて「運用オーバーヘッドを削減する（運用負担を減らす）」という
  Wrangler等）」を選択させるためのキーワードとして使われる。
- **実務での使い方**: AIプラットフォームの設計において、「データエンジニアが行うべき重いETL処理（G
- **副業での需要**: ★★☆（MLOps基盤のアーキテクチャ設計・コンサルティング案件において、属人化を

SageMakerエンドポイント

- **概要**: 学習済みの機械学習モデルを本番環境でホストし、HTTPリクエストに対してリアルタイムで推論
- **試験ポイント**: 複数インスタンスによるトラフィックの自動分散機能や、「自動スケーリング」を標準的
- **実務での使い方**: アプリケーション（Webアプリやモバイル）の実装チームに、作成したMLモデルを
- **副業での需要**: ★★★（MLエンジニアとして、単なるモデル学習だけでなく「本番で安定して動くAPI

SageMakerエンドポイント自動スケーリング

- **概要**: CloudWatchのメトリクス（CPU、メモリ、リクエスト数等）に基づいて、推論用のインスタンス
- **試験ポイント**: 「最小インスタンス数を0に設定する」ことでトラフィックがない時間帯のコストを完全
- **実務での使い方**: 日中だけアクセスが集中し、夜間や休日はほとんど使われないような業務予測システム
- **副業での需要**: ★★★（ML関連のクラウドインフラ構築において、「コストを抑えたい」クライアント

AWS Lambda（MLホスティングにおける制限）

- **概要**: イベント駆動でコードを実行するサーバーレスサービスだが、最大15分の実行時間やメモリ上限
- **試験ポイント**: 手軽な反面「コールドスタートによる遅延」や「大規模モデルがメモリに収まらない」
- **実務での使い方**: 単体でのMLホスティングではなく、軽量な前処理・後処理関数や、SageMakerエンド
  Gateway連携）として間にかませて利用する。
- **副業での需要**: ★★☆（非常に軽量なモデル（scikit-learnのロジスティック回帰等）であればLambda

Amazon ECSとFargate（MLホスティングにおける制限）

- **概要**: コンテナを実行するオーケストレーションサービス。MLモデルを組み込んだコンテナをデプロイ
- **試験ポイント**: 推論用途において「静的なタスク数設定ではトラフィック変動に追従できず余分なコス
- **実務での使い方**: 既に企業全体で全システムをECS/Fargate上で運用する強力な規約・独自の運用基盤が
- **副業での需要**: ★★☆（既存のアプリケーション基盤（ECS）にML
  APIを相乗りさせるような案件では、Dockerコンテナ化とECSタスク定義・運用の知見が求められる）

コスト最適化とスケーラビリティのバランス

- **概要**: アクセスの少ない時間帯の不要なインスタンス起動を抑える（コスト最適化）と同時に、突発的な
- **試験ポイント**: この2つの相反する要件を両立するシナリオが問われ、「SageMakerの自動スケーリング
- **実務での使い方**: 負荷テストを実施して1インスタンスあたりの処理限界（スループット）を測定し、そ
- **副業での需要**: ★★★（インフラエンジニア、MLOpsエンジニアとしての経験やプロ意識が最も如実に

二値分類の混同行列（Confusion Matrix）

- **概要**: 予測結果を「真陽性（TP）」「偽陽性（FP）」「真陰性（TN）」「偽陰性（FN）」の4象限に
- **試験ポイント**: 不正検知などのユースケースにおいて、「偽陰性（FN：不正の『見逃し』）」を減らす
- **実務での使い方**: 単純な正解率（Accuracy）では測れない「誤検知（アラート過多）」や「見逃し（重
- **副業での需要**: ★★★（あらゆるML分類モデル構築案件において、構築したモデルの特性とビジネス影

再現率 (Recall)

- **概要**: `TP ÷ (TP + FN)` で計算される、実際の陽性のうちどれだけ正しく陽性として検出できたかの割合
- **試験ポイント**: 空港のセキュリティ（危険物）、がん診断、不正検知など「**見逃し（FN）によるコスト**
- **実務での使い方**: 異常検知システムの要件定義時に「100回のうち1回でも見逃したら大事故になるため
- **副業での需要**: ★★★（需要予測や異常検知など、クライアントのビジネスにおける「MLの価値」を定

適合率 (Precision)

- **概要**: `TP ÷ (TP + FP)` で計算される、モデルが「陽性」と予測したもののうち、本当に陽性であった割
- **試験ポイント**: スパムメールフィルタなど「**誤検知（FP）によるコスト・業務支障が高い場面**」で、見
- **実務での使い方**: 営業の架電リスト抽出AIなどで「抽出された全リストに電話すると無駄打ちで業務に
- **副業での需要**: ★★★（「とりあえず異常なものを全部検知して」と言われるAI化案件に対し、「オペ

F1スコアとAUC

- **概要**: F1スコアは適合率と再現率のバランスを取る「調和平均」。AUCはROC曲線の下の面積であり、
- **試験ポイント**: 「適合率と再現率を両立（バランスよく評価）したい場合はF1スコア」、また「特定の
- **実務での使い方**: 不正検知など、正例（異常）と負例（正常）のデータ数が極端に異なる不均衡データ
- **副業での需要**: ★★☆（データサイエンティストとして、モデル生成後の精度の評価レポートを作成・提

データレイクとデータ統合

- **概要**: 「データレイク」は様々な形式・スキーマの構造化/非構造化データを丸ごと保存する集中型リポ
- **試験ポイント**: MLモデルのトレーニング用に「安全にアクセス・統合された集中型データストアが必要
- **実務での使い方**: 機械学習チーム（データサイエンティスト等）が、オンプレミス・S3・各種DBに散ら
- **副業での需要**: ★★★（企業内のデータ活用を推進するための最初のステップ「データ統合基盤づくり」

AWS Lake Formation

- **概要**: S3、オンプレDB、各種データソースからデータを自動的に収集・カタログ化（AWS Glue等と連携）し、複雑なアクセス制御を持ったセキュアなデータレイクを短期間で構築するマネージ
- **試験ポイント**: 「S3やオンプレのMySQL等、多様なデータソースから自動的にデータ収集する」「メタ
- **実務での使い方**: 企業内に点在するサイロ化されたデータを一箇所に集め、誰がどのカラムまでアクセス
- **副業での需要**: ★★★（金融・医療などデータガバナンス要件が厳格なクライアント向けのデータレイ

Amazon Redshift（データ統合要件における制限）

- **概要**: ペタバイト規模の大規模データを高速に分析・クエリするためのクラウドデータウェアハウス（D
- **試験ポイント**: 高速分析には最適だが、「多様なソースからの『自動データ集約レイヤー』」としては
- **実務での使い方**: 分析用に前処理・統合済みの構造化データを高速にスライス＆ダイス（多次元分析）
- **副業での需要**: ★★★（データエンジニアリング案件として、構築されたデータレイク（S3等）の後段

Amazon Kinesis Data Streams（データ統合要件における制限）

- **概要**: アプリケーションやデバイスから発生するミリ秒単位のリアルタイムストリーミングデータを継続

- **試験ポイント**: 「リアルタイムのストリーミング用途」には最適だが、「オンプレのDBやバッチデータ
- **実務での使い方**: IoTセンサーデバイスからの逐次データや、決済システムのリアルタイム不正アクセス
- **副業での需要**: ★★☆（リアルタイムな分析・ML推論が求められる高度な案件において必須となるスキ

Amazon DynamoDB（データ統合要件における制限）

- **概要**: ミリ秒単位の応答速度を提供する、高パフォーマンスでスケーラブルなフルマネージドNoSQLデ
- **試験ポイント**: 「アプリ向けデータストア」としての用途に特化しており、「複数ソースのデータを自動
- **実務での使い方**: Webアプリのセッション管理やユーザープロファイル情報など、「特定の少数のキーに
- **副業での需要**: ★★☆（Webアプリケーション開発全般におけるデータベースとして最も一般的に使われ

Amazon Transcribe

- **概要**: 音声データや動画ファイルから対象の発話内容（テキスト）を自動的に抽出（文字起こし）する
- **試験ポイント**: 「音声データをテキスト化したい」という要件に対する絶対的な正解。カスタム語彙を使
- **実務での使い方**: コールセンターの通話録音のテキスト化・分析パイプラインや、自動字幕生成システム
- **副業での需要**: ★★★（動画や音声の文字起こしを自動化するシステム構築案件は根強い需要があり、S

Amazon Translate

- **概要**: 55以上の言語ペアをサポートし、リアルタイムおよびバッチ処理でニューラル機械翻訳を提供す
- **試験ポイント**: カスタム用語集（Custom Terminology）を使用して、特定のドメイン（医療用語やブラ
- **実務での使い方**: グローバル展開するWebサイトの動的翻訳や、海外からのインバウンド向けカスタマ
- **副業での需要**: ★★☆（多言語対応の要件があるSaaS開発案件などで手軽に組み込める翻訳APIとして重

Amazon Bedrock

- **概要**: Anthropic ClaudeやLlama、Titanなど、複数の主要な基盤モデル（LLM）に対して共通のAPI経由
- **試験ポイント**: インフラ管理やGPUの調達なしに、テキスト生成・要約・QAなどのタスクを「複数のモ
- **実務での使い方**: 自社独自のデータを組み合わせた社内検索システム（RAG）のLLM推論エンジンとし
- **副業での需要**: ★★★（現在最も引き合いが強い「社内用生成AI環境構築案件」の中核であり、Bedroc

Amazon Rekognition（音声認識不可という制約）

- **概要**: 画像および動画内のオブジェクト、顔、テキスト（映像内に映り込んだ文字）などを検出・分析
- **試験ポイント**: 「動画内の『音声』をテキスト化する」という要件に対しては機能しないため（映像内の
- **実務での使い方**: ユーザーがアップロードした顔写真による本人確認（eKYC）や、不適切コンテンツ（
- **副業での需要**: ★★☆（画像解析系AIを組み込む案件ではデファクトスタンダードであり、実装も容易な

Amazon Comprehend（音声認識不可という制約）

- **概要**: テキストデータから感情、エンティティ（固有名詞）、キーフレーズなどを抽出・分類する自然言
- **試験ポイント**: テキスト分析には最適だが、「音声や動画データからテキストへ変換する機能（Speech to-Text）」はないため、文字起こし要件では不正解となる切り分けがよく出る。
- **実務での使い方**: SNSの口コミ分析、アンケート結果の自由記述のネガポジ判定（感情分析）、コール
- **副業での需要**: ★★☆（テキストマイニングや顧客の声（VoC）分析ダッシュボード構築案件などで、自

モデルの自前学習とマネージドサービスの比較（開発スピードと保守性）

- **概要**: AIを導入する際、データを集めてモデルを一から設計・学習させる手法（自前開発）と、学習済
  AIサービス（TranscribeやRekognition等）をAPIコールするだけの手法との比較基準。
- **試験ポイント**: 「最短時間で」「最小限の開発労力で」という要件に対しては、よほど独自性の高いタ
- **実務での使い方**: プロジェクトの要件定義フェーズにおいて、まずはAWSの高精度なマネージドAIサー
- **副業での需要**: ★★★（技術顧問やコンサルティングにおいて、「MLの自前開発には莫大なコストがか

SageMaker推論方式とパフォーマンス特性（リアルタイム vs 非同期）

- **概要**: SageMakerは用途に応じて「リアルタイム（完全同期・常時起動・低遅延）」「非同期（キュー
- **試験ポイント**: 「銀行アプリなどの即時判断が必要（数ミリ秒待機）」という要件では「リアルタイム推
- **実務での使い方**: ユーザーの操作に対する即時フィードバックが必要なWeb/スマホアプリの裏側にはリ
  Inference）を用いてコストと堅牢性を最適化する。
- **副業での需要**: ★★★（MLエンジニアとして「作ったモデルをどのインフラでどう動かすか」の要件定

SageMaker Model Monitor

- **概要**: 本番デプロイ済みのエンドポイントに流れる入力データと推論結果をサンプリングし、データの
- **試験ポイント**: 「運用中のモデルの性能劣化（データドリフト・概念ドリフトなど）を自動検知し通知
- **実務での使い方**: 金融スコアリングや商品推薦システム等で、社会情勢の変化により学習時と現在の「
- **副業での需要**: ★★★（単発のモデル構築ではなく「本番運用を前提とした高品質なMLOps基盤」の構

SageMaker Inference Recommender

- **概要**: 自作したモデルに対してベンチマーク負荷テストを自動実行し、エンドポイントの推論に最適な
- **試験ポイント**: あくまで「インフラ構成（インスタンス等）の最適化推奨機能」であり、「モデルの品
  Monitor」の役割である、という明確な使い分けが問われる。
- **実務での使い方**: プロダクション環境にモデルをリリースする直前の検証フェーズで、推論に最適なイン
- **副業での需要**: ★★☆（インフラコストを圧縮したい・ピークトラフィックに耐えられる構成を組みたい

SageMaker Debugger

- **概要**: 機械学習モデルの**トレーニング（学習）中**に発生する各種の問題（勾配消失、過学習、GPU未満
- **試験ポイント**: 「トレーニングプロセス中に問題を見つけて即座に停止（またはCloudWatchにアラー
  Monitorとの違いに注意。
- **実務での使い方**: 実験段階の学習ジョブに対してDebuggerの組み込みルールを設定しておき、学習がう
- **副業での需要**: ★★☆（数日間にわたる大規模なモデル学習を行う際、意図せぬ学習失敗による莫大な

機械学習の代表的なトレーニング課題（消失勾配・GPU未満稼働・過学習）

- **概要**: モデル学習中に発生する問題。
  - **消失勾配 (Vanishing Gradient)**: 深層学習において、入力層に近い重みが更新されなくなり学習
  - **GPUの未使用 (GPU Underutilization)**: データの読み込み（データローダー等）が遅く、計算資
  - **過学習 (Overfitting)**: 訓練データに適合しすぎて検証データ/未知データへの予測精度が落ちる現

- **試験ポイント**: これら学習特有の詳細な問題を「開発者が独自のスクリプトを書いて手動検知」するの
  Debuggerの組み込みルールを利用して自動検出する」ことが模範解答となる。
- **実務での使い方**: Debuggerのプロファイラを利用して「GPU使用率が低い」と出た場合、学習スクリ
- **副業での需要**: ★★☆（学習の歩留まりやインフラ最適化のコンサルティングにおいて、これらの現象

TensorBoardとCloudWatchメトリクス（学習監視における課題）

- **概要**: TensorBoardはTensorFlow等の損失・勾配などを可視化するツール。CloudWatchはCPU/GPU使
- **試験ポイント**: どちらも「可視化」はできるが、「消失勾配や過学習といった**ML特有の問題を自動検出**
- **実務での使い方**: エンジニア自身が手動でグラフを見て学習の進捗を判断する場合にはTensorBoardをそのまま用い、自動停止やアラートの仕組みを組みたい場合は前述のSageMaker Debuggerを採用するといった使い分けを行う。
- **副業での需要**: ★★☆（TensorBoard等既存ツールに慣れ親しんだMLエンジニアに対し、単なる可視化を超えたアクション自動化（運用効率化）の観点からSageMaker Debuggerのメリットを説く提案力が求められる）

AWS Lake Formationとタグベースのアクセス制御 (LF-Tags)

- **概要**: Lake Formationは、S3等に構築したデータレイクに対するセキュアなアクセス制御とデータガバ
  Formationタグ(LF-Tags)」を利用することで、メタデータを用いた柔軟な認証・認可が可能になる。
- **試験ポイント**: 「複雑なIAMポリシーを使用せずに、柔軟で運用しやすいアクセス制御を実現したい」
  Formationのタグ（LFタグ）ベースのアクセス制御を使用する」のが最強の正解として頻出する。
- **実務での使い方**: プロジェクトごとに「キャンペーンA」といったタグをデータとユーザー双方に付与し
- **副業での需要**: ★★★（データガバナンスが厳しく求められるエンタープライズのデータ基盤構築案件
  Tagsを用いたきめ細かい（列/行レベルの）柔軟なアクセス制御の設計スキルは非常に評価が高い）

AWS Glue Data Catalog

- **概要**: 様々なデータソース（S3やDB等）のメタデータ（どこにどんなテーブルやスキーマ、パーティシ
- **試験ポイント**: Lake FormationはS3の実データに直接アクセス制御をかけるだけでなく、「Glue Data Catalogと統合」されており、カタログを通じたAthena等からのクエリ実行権限を一元管理できる
- **実務での使い方**: S3に投げ込まれた非構造化・半構造化データをGlue Crawlerでクロールして Data Catalogに自動登録し、そのカタログ情報をLake Formationで保護しながらデータ分析チームに公開する、という一連のパイプラインとして使用する。
- **副業での需要**: ★★★（あらゆるAWSデータ分析アーキテクチャ（Athena/Redshift/EMR）の中心であ

IAMポリシーやS3バケットポリシー（複雑なデータレイクでの限界）

- **概要**: ユーザーやAWSリソースに対する最も基本となるアクセス制御の仕組み。
- **試験ポイント**: 「S3に生データがあり、Athena経由で分析させたいが、ユーザーごとに特定の列は見せ
- **実務での使い方**: 巨大なデータレイクや多くの分析ユーザーが絡む複雑な基盤では、IAMやS3バケット
  Lake Formation」にアクセス管理を委譲（統合）する運用へ切り替える。
- **副業での需要**: ★★☆（「管理しきれない無数のIAMポリシー」に苦しんでいるクライアントに対し、
  Formationによる中央集権的なガバナンスへとリファクタリングする提案力が求められる）

SageMaker Model Registry（モデル運用管理）

- **概要**: 機械学習モデルのバージョン情報を一元管理し、モデルごとに「説明」「検証メトリクス」「承
- **試験ポイント**: 「モデルのバージョン管理や本番環境へのデプロイ承認ワークフローを実装したい」と
  Pipelines等）との統合が極めて容易である点が問われる。
- **実務での使い方**: データサイエンティストがモデルを作った後、マネージャーなどのレビュアーがダッシ
- **副業での需要**: ★★★（MLOpsパイプライン（CI/CD/CT基盤）構築案件において、開発環境から本番
  Registry」の設計・導入は、案件の根幹となるため非常に需要が高い）

Amazon ECR（モデルレジストリとしての制約）

- **概要**: Dockerコンテナイメージを保存・管理するコンテナレジストリサービス。
- **試験ポイント**: コンテナの管理には必須だが、「機械学習『モデル』のメタデータ管理、承認ワークフ
- **実務での使い方**: SageMakerで推論に使う「カスタムコンテナイメージ」の保存先としてはECRを使う
  Artifacts）」自体のバージョン管理や承認フローは上述のModel Registryを利用する、という使い分けを徹底する。
- **副業での需要**: ★★☆（AWSでのコンテナ運用において必須のベース知識。ML案件だけでなく全てのイ

モデル管理システムにおける運用オーバーヘッド

- **概要**: 独自のスクリプトや汎用サービス（ECRやS3など）を組み合わせてモデルの管理システム（承認
- **試験ポイント**: カスタムソリューションや自前構築は「運用オーバーヘッドを増加させる」ため試験で
  RegistryやPipelinesなど）を選択することで「運用オーバーヘッドを削減する」のがAWS推奨の正解と
- **実務での使い方**: クライアントが「自分たちで承認管理用のWebアプリを作る」と言い出した際に、「
- **副業での需要**: ★★★（AWSの思想である「Undifferentiated Heavy Lifting（差別化を生まない重労働＝インフラ管理などのオーバーヘッド）の排除」を体現したアーキテ

AWS Trainium インスタンス（機械学習における持続可能性・エコ）

- **概要**: AWSが独自開発した、機械学習の「トレーニング（学習）」に特化した高性能かつ省電力なカス
- **試験ポイント**: 「トレーニングのパフォーマンスを維持・向上させつつ、**エネルギー効率（サステナビ**
  P4等）よりもエコである点が問われる。
- **実務での使い方**: サステナビリティ（ESG投資）目標を掲げる大企業のAIプロジェクトにおいて、従来の
- **副業での需要**: ★★☆（モデルの精度向上ではなく、「AWSリソースのコストと電力消費の削減」とい

Amazon SageMaker Ground Truth（トレーニング省電力化における制約）

- **概要**: 人間（クラウドソーシング等）や自動化ツールを用いて、機械学習用の生データに対してアノテー
- **試験ポイント**: データ準備としては必須だが「トレーニングジョブ自体のエネルギー使用量や計算リソ
- **実務での使い方**: MLプロジェクトの初期フェーズにおいて、社内にアノテーションスタッフがいない場
  Mechanical Turk等）や専門ベンダーへセキュアにラベル付けタスクを外注するプラットフォームとして
- **副業での需要**: ★★☆（AI開発の前段である「教師データ作成」のパイプライン構築案件において、セ

AWS Lambda等による推論（トレーニング省電力化における制約）

- **概要**: イベント駆動でコードを実行する完全なサーバーレスコンピューティングサービス。

- **試験ポイント**: 軽量なモデルの「推論（Inference）コスト」の削減には非常に有効だが、「モデルの『
- **実務での使い方**: 数MB〜数百MB程度の軽量な推論モデル（scikit-learn等）であれば、常時起動のSageMakerエンドポイントを使わずにLambdaに直接モデルをデプロ
- **副業での需要**: ★★☆（要件が極めてシンプルな推論APIを作る案件において、Lambda+API Gatewayという基本構成でMLエンジニアリングを安価に提供する設計スキルとして役に立つ）

分散トレーニング（サステナビリティにおける制約）

- **概要**: 複数のインスタンス（GPU群）を用いて一つの巨大なモデルの学習を並列処理することで、トレ
- **試験ポイント**: 「時間を短縮」することはできるが、「複数のインスタンスを立ち上げるため、トータ
- **実務での使い方**: 何日もかかる大規模LLMや膨大な画像認識モデルの学習を、AWSの強力なネットワー
- **副業での需要**: ★★☆（PyTorchのDDP機構等の知識とAWSインフラの知識を両方持ち合わせた上で、

Amazon Data Firehose

- **概要**: リアルタイムのストリーミングデータ（ログやIoTデータなど）を収集し、S3、Redshift、Open
- **試験ポイント**: 「バッファ間隔（最速0秒〜900秒）」と「バッファサイズ」を調整することで、コスト
- **実務での使い方**: Webサーバーのアクセスログ（Fluentd等から）をFirehoseで受け取り、Lambda関数 Serviceに流し込んでリアルタイムのインシデント監視ダッシュボードを構築する。
- **副業での需要**: ★★★（AWSを用いた「ログ収集・分析基盤」構築において、Kinesis Data Streamsと並ぶ絶対的なデファクトスタンダードであり、このバッファリング設定の設計スキルは

Amazon OpenSearch Service

- **概要**: 大量のログ分析やリアルタイムの全文検索、データ可視化（ダッシュボード）を提供するElastics
- **試験ポイント**: 「ほぼリアルタイム（サブ秒レイテンシー）でデータを可視化・検索したい」「組み込
- **実務での使い方**: Firehoseから絶えず流れてくる本番環境のエラーログや決済トラフィックデータをリア Dashboards）で運用チームが24時間体制で監視する。
- **副業での需要**: ★★★（ログ分析、Eコマースアプリの豊富な全文検索エンジン構築など、用途が多岐に

AWS DataSync（リアルタイム処理における限界）

- **概要**: オンプレミスとAWSストレージ（S3等）間などで、ペタバイト級の大容量データを「高速かつセ
- **試験ポイント**: あくまで「ストレージ間のスケジュール・オンデマンドのファイル移動」であり「リア
- **実務での使い方**: データレイク構築の第一歩として、長年オンプレミスのNASやファイルサーバーに眠
- **副業での需要**: ★★☆（企業システムのクラウド移行（マイグレーション）案件において必須となるツ

Amazon SQS（ストリーミングデータ直接配信における限界）

- **概要**: アプリケーション間で非同期にメッセージの送受信が行える、マネージドなメッセージキューイ
- **試験ポイント**: システム間の疎結合化や処理のキューイング・バッファリングには最適だが、「OpenS
- **実務での使い方**: 大量のリクエストを一旦SQSで受け止め、自分たちのワーカー（Lambda等）のペース
- **副業での需要**: ★★☆（マイクロサービスアーキテクチャの基本コンポーネントであり、AWSでのWeb

リフトアンドシフト（Lift and Shift）移行戦略

- **概要**: 既存のアプリケーションのアーキテクチャやコードを基本的に変更（書き直し）することなく、
- **試験ポイント**: 「移行速度（スケジュール）を最優先にしたい」「コードを書き直すための運用リソー
- **実務での使い方**: まずはオンプレミスのサーバーやコンテナ群をそのままEC2やEKSに乗せ換えてデー
- **副業での需要**: ★★★（企業システムのAWS移行コンサル案件において、「まずは短納期でLiftしましょ

Amazon ECR (Elastic Container Registry) の特徴

- **概要**: AWSが提供する、Dockerコンテナイメージを安全に保存、管理、デプロイするためのフルマネー
- **試験ポイント**: コンテナイメージの保存場所という基本に加えて、イメージの暗号化や脆弱性の自動スキ
- **実務での使い方**: CI/CDパイプライン（CodeBuildやGitHub Actions）の最後で作成されたDockerイメージをpushし、本番のEKS（Kubernetes）やECSクラスターか
- **副業での需要**: ★★★（Dockerを利用したモダンなWebアプリケーション開発やML API構築案件において、ECRの概念やIAMアクセス制御、ライフサイクルポリシー（古いイメージの自動

Amazon EKS (Elastic Kubernetes Service) の特徴

- **概要**: AWS上でオープンソースのKubernetesクラスターを実行できるマネージドサービス。自前で構築
- **試験ポイント**: 「現在オンプレミスでKubernetesを利用している企業」の移行という文脈で、「既存の
- **実務での使い方**: 数十〜数千のマイクロサービスを運用するような大規模なプロダクトにおいて、トラフ
- **副業での需要**: ★★☆（EKSのインフラ構築や運用・トラブルシューティング案件は非常に単価が高い

ビジネス要件に基づく評価メトリクスの選択（偽陰性 vs 偽陽性のコスト）

- **概要**: 機械学習モデルの予測外れには2種類あり、「実際は『正』なのに『負』と見逃すこと（偽陰性: False Negative）」と「実際は『負』なのに『正』と過剰に検知すること（偽陽性: False Positive）」のどちらがビジネスに大きなコスト（損害）を与えるかを比較評価する概念。
- **試験ポイント**: MLA試験において極めて重要視される考え方。
  - **偽陰性のコストが致命的な場合**（例：命に関わる病気の診断見逃し、空港での危険物見逃し）：
  - **偽陽性のコストが致命的な場合**（例：誤検知による不要な処置のコスト増大、迷惑メールの誤分類
- **実務での使い方**: 機械学習プロジェクトの要件定義フェーズにおいて、クライアントに「1回の検知漏れ
- **副業での需要**: ★★★（データサイエンティストやAIコンサルタントとしての真の介在価値はアルゴリズ

SageMaker シャドウテスト（Shadow Testing）

- **概要**: 新しい機械学習モデルを本番環境にデプロイする際、本番トラフィック（ライブデータ）の「コ
- **試験ポイント**: 「**エンドユーザー（本番環境）に全く影響を与えずに**（リスクゼロで）、新しいモデルの
- **実務での使い方**: オフライン評価（検証データ）では見抜けない、実世界データのドリフトやスパイク
- **副業での需要**: ★★★（MLOps運用フェーズにおいて、クライアントの「新モデルへの切り替えに伴う

各種デプロイメント戦略（Blue/Green・Canaryとシャドウテストの比較）

- **概要**: SageMaker等でのモデルバージョンの切り替え（トラフィックシフト）戦略。
  - **Blue/Green (All-at-once)**: 準備した新環境（Green）にトラフィックを「一度にすべて」切り替
  - **Blue/Green (Canary)**: トラフィックの一部（例：10%）を新モデルに流し、問題なければ徐々に

  - **Blue/Green (Linear)**: 一定時間ごとに一定の割合で段階的にトラフィックをシフトさせる。
- **試験ポイント**: CanaryやLinearはリスクを抑えてはいるものの、「**新しいモデルの推論結果がそのまま**
- **実務での使い方**: 新機能のA/Bテスト（ビジネス上のKPI比較）を行いたい場合はCanaryルーティング等
- **副業での需要**: ★★☆（エンドポイントのデプロイ戦略設計において、クライアントの許容リスク（Do

SageMaker Debuggerの用途と限界（デプロイ前評価について）

- **概要**: モデルのトレーニング「中」の推移や異常を監視するツール。
- **試験ポイント**: あくまで「トレーニング中の問題（勾配の消失、過学習、GPU未満稼働など）を検出す
- **実務での使い方**: 学習時はDebuggerで異常をストップし、推論器構築時はRecommenderでインスタン
  Monitorでドリフトを監視する、というライフサイクル（MLOps基盤）を繋ぎ合わせて構築する。
- **副業での需要**: ★★★（MLOps全体のアーキテクチャ設計では、これら「AWSマネージドサービスの

確率的勾配降下法（SGD）と学習率（Learning Rate）

- **概要**: SGD（Stochastic Gradient Descent）は、ニューラルネットワークのモデルの重み（パラメータ
  Rate）」は、その探索において「1回の更新の歩幅（ステップサイズ）」を決める最重要のハイパーパラ
- **試験ポイント**: 学習率が高い（歩幅が広すぎる）と「速く進むが最適解を通り過ぎてしまい収束しない
- **実務での使い方**: 学習率の調整はディープラーニングにおける最も繊細な職人技（チューニング）の一つ
  Rate Scheduler」や最適な学習率を自動で探すSageMaker Automatic
  Model Tuning（HPO）を多用する。
- **副業での需要**: ★★★（モデル開発コンサルティング案件において、学習率チューニングの知見がないと

損失の振動（Oscillation）パターン

- **概要**: トレーニング中、損失関数（予測値と実測値のズレ）の値が「減少→増加→減少→増加」と同じ
- **試験ポイント**: 「トレーニング損失と検証損失の両方が高く、なおかつ損失が振動している」という障害
- **実務での使い方**: TensorBoardなどでLearning Curve（学習曲線）のグラフを見た際、ギザギザに暴れて
- **副業での需要**: ★★☆（トラブルシューティング（なぜ学習がうまくいかないのか？）を単一のグラフ

早期停止（Early Stopping）の限界と制約

- **概要**: 学習を続けるうちに「トレーニングデータには適合していくが手元にない検証データの精度が悪化
- **試験ポイント**: Early Stoppingは「過学習」を防ぐための特効薬ではあるが、前述のように**「トレーニン**
- **実務での使い方**: 適切な学習率を設定して順調に学習が進むようになった「後」で、無駄なGPUコスト
  Debuggerのルール等と組み合わせて必ず設定しておく安全装置として利用する。
- **副業での需要**: ★★☆（インフラコスト削減（FinOps）とモデルの汎化性能向上の両得を狙えるため、

テストデータセットサイズの増加における限界

- **概要**: 最終的なモデルのパフォーマンス評価に使う手持ちのテストデータを増やすアプローチ。
- **試験ポイント**: テストデータを増やすと「評価の信頼性（統計的な確からしさ）」は上がるが、**「モデル**
- **実務での使い方**: 万能な解決策のように思える「データの増量」だが、学習データ増強（Data
  Augmentation）は精度向上に寄与する可能性があるものの、「純粋なテストデータだけを増やしても
- **副業での需要**: ★☆☆（機械学習プロジェクトのプランニングにおいて、闇雲にアノテーション（正解ラ

Amazon Athena (サーバーレスクエリとCTAS)

- **概要**: S3に保存された膨大なデータ（CSVやJSON、Parquet等）に対して、サーバーを立てることなく
- **試験ポイント**: 「S3上の生データを最小限の運用オーバーヘッドでクエリしたい」「条件に基づいてデ
  TABLE AS SELECT）クエリを使用するのが最強の正解として頻出する。
- **実務での使い方**: データレイク（S3）に入ってきた生のログファイルを、とりあえずAthenaで叩いて中
- **副業での需要**: ★★★（データ分析・MLデータ前処理の基本ツールであり、サーバー運用が不要なため

S3レプリケーション（クエリ機能における制約）

- **概要**: クロスリージョン（CRR）や同一リージョン（SRR）で、S3バケット間でオブジェクトを自動コ
- **試験ポイント**: バックアップやデプロイ用データの移行には最適だが、「S3上のデータに対する『クエ
- **実務での使い方**: MLモデルの学習済みパラメーターファイルや、絶対に消えてはならないコンプライア
- **副業での需要**: ★★☆（インフラ・セキュリティ要件の厳しい金融やエンタープライズのAWS基盤設計

S3 Object Lambda（大容量データ処理における限界）

- **概要**: アプリケーション側がS3からオブジェクトをGETする「通過中」のタイミングで、透過的にLam
- **試験ポイント**: アプリケーション側の修正なしでPII（個人情報）をマスクするような用途には便利だが
- **実務での使い方**: サードパーティ製のSaaS（ソースコードがいじれないアプリ）にS3を見せる際、生デ
- **副業での需要**: ★☆☆（かなりエッジの効いた高度な機能であり、知らないとマズい場面は少ないが、

AWS Glue for Apache Spark（アドホッククエリにおける限界）

- **概要**: 分散処理フレームワークであるApache Sparkを使用して、大規模なデータの変換やETL（抽出・
- **試験ポイント**: 巨大なデータパイプライン構築には必須だが、「S3上のデータを単に『クエリ（SQL検
- **実務での使い方**: Athena（標準SQL）だけでは表現できないような複雑なデータクリーニング、大規模
- **副業での需要**: ★★★（昨今のデータレイク/データウェアハウス構築案件ではGlueが中心となるため、

Amazon Data Firehose（既存データ一括処理における限界）

- **概要**: 絶え間なく流れてくる「ストリーミングデータ」を受け取り、指定の宛先（S3やRedshift等）へ
- **試験ポイント**: アプリケーションから絶えず流れてくる（Streaming）データには適しているが、**「すて**
- **実務での使い方**: WebバックエンドやIoTデバイスから出力されるログなどの「これから継続的に発生す
- **副業での需要**: ★★☆（データ基盤構築全体における「収集フェーズ」の要であり、Kinesisと合わせて

不正検出（Fraud Detection）問題の特性

- **概要**: クレジットカードの不正利用やスパムアカウントの検出など「極めて発生頻度が低く（クラスイ
- **試験ポイント**: こうした「クラス不均衡」「非線形」「複雑な特徴量の相互作用」を持つ課題に対し、
- **実務での使い方**: 不正検出の要件定義において、「正常なデータが99.9%、異常なデータが0.1%」とい
- **副業での需要**: ★★★（金融系やEC系のクライアントから最も相談されやすい機械学習テーマの一つ。

LightGBM（勾配ブースティングフレームワーク）

- **概要**: 決定木をベースとした強力な勾配ブースティングアルゴリズム。SageMakerの組み込みアルゴリズ

- **試験ポイント**: 前述の不正検出のような「クラス不均衡に強く、カテゴリカルデータや非線形な複雑な
- **実務での使い方**: 構造化データ（テーブルデータ）の分類・回帰タスクにおいて、「とりあえず最初はL
- **副業での需要**: ★★★（テーブルデータを扱う全ての案件において大黒柱となる予測モデル。Kaggle等の

Linear Learner（線形学習器）における限界

- **概要**: ロジスティック回帰や線形SVMを含んだ、特徴量間の「線形関係」を捉えるためのシンプルで解
- **試験ポイント**: シンプルで高速だが、**「不正検出のような複雑で非線形な関係を捉える能力はない（限**
- **実務での使い方**: 大まかなトレンド（気温とアイスの売上など）を掴みたい場合や、モデルの「なぜその
- **副業での需要**: ★★☆（アルゴリズム自体の需要というより、「ディープラーニングやLightGBMなどの

K-means法（教師なし学習）における限界

- **概要**: 似た特徴を持つデータをグループ（クラスター）に自動で分類する「教師なし学習」の代表的アル
- **試験ポイント**: データの構造理解や未知の異常検知には使えるが、**「（正解ラベルが存在する）不正検**
- **実務での使い方**: 全顧客データから「なんとなく似た購買傾向を持つ5つのグループを発見したい（顧客
- **副業での需要**: ★★☆（マーケティングコンサルティング等において、顧客の行動履歴を自動でクラスタ

Neural Topic Model (NTM / ニューラルトピックモデル)における限界

- **概要**: 文書のコレクション（大量のテキスト）から潜在的な「トピック（話題）」を発見するための「
- **試験ポイント**: 不正検出のような「トランザクションログや顧客プロファイル（構造化データ）」を用い
- **実務での使い方**: コールセンターに蓄積された数万件のお問い合わせテキスト（非構造化データ）から
- **副業での需要**: ★★☆（NLP案件や、VoC（Voice of Customer）分析等の文脈で「眠っているテキスト

IAMロールと権限管理の一元化

- **概要**: IAMロールは、AWSリソース（EC2やSageMakerノートブックなど）やアプリケーションに対して
- **試験ポイント**: 「複数あるSageMakerノートブックインスタンスのS3アクセス権限を一括で管理したい
- **実務での使い方**: 本番環境において、S3バケットに対するReadOnlyアクセス権限を持つ「データ分析用
- **副業での需要**: ★★★（AWSの根幹をなすセキュリティ管理スキルであり、最小特権の原則（Principle of Least Privilege）を設計に落とし込む力は、あらゆるAWS案件（構築・運用・監査）において最重要

IAMグループにおける用途と制約

- **概要**: 複数の「IAMユーザー（人間）」を論理的に束ねてグループ化し、ポリシー（権限）を一括で付与
- **試験ポイント**: 複数人に対する権限付与には便利だが、**「AWSリソース（SageMakerノートブック等**
- **実務での使い方**: 組織内で「データサイエンティスト」グループや「インフラエンジニア」グループを作
- **副業での需要**: ★★☆（企業向けのIAMアカウント設計案件において、組織図に応じたIAMグループとポ

IAMユーザーにおける制約

- **概要**: 人間やプログラムがAWSを利用する際に特定するためのID（認証情報）。ユーザー名/パスワード
- **試験ポイント**: 人間がログインするための基本要素だが、**「SageMakerノートブックインスタンスなど**

- **実務での使い方**: セキュリティの観点から最近のベストプラクティスでは、強力な権限を持つIAMユーサ
  IAM Identity Center）を利用したフェデレーション接続と一時的クレデンシャルに移行が進んでいる。
- **副業での需要**: ★★★（レガシーな環境からモダンな認証基盤への移行コンサルティングにおいて、「

Amazon EMRクラスターのノードアーキテクチャ（3種の役割）

- **概要**: AWS上でHadoopやSparkといった分散処理フレームワークを実行するためのマネージドクラスタ
  - **プライマリ（旧マスター）ノード**: クラスター全体の管理、ジョブのスケジューリング、メタデー
  - **コアノード**: 各種処理の実行（MapReduce等）を行うと同時に、「HDFS（分散ファイルシステム
  - **タスクノード**: 計算処理「のみ」を担当し、**データを一切保持しない**手足。
- **試験ポイント**: それぞれ「データを保持しているか否か」が最大の出題ポイントになり、後述するイン
  Demandか）の配置戦略の判断基準となる。
- **実務での使い方**: EMRクラスターを構築する際、永続的なデータ管理と一時的な計算リソースのスケー
- **副業での需要**: ★★☆（データエンジニアリング案件において、大規模データ処理のパフォーマンスチ

On-Demandインスタンス（確実な実行とデータ保護）

- **概要**: 中断されることなく、必要な時に起動し使った分だけ支払う通常のEC2インスタンス。
- **試験ポイント**: 「データ損失が許容されない」という要件において、クラスターの頭脳である「プライ
  Demandインスタンス（またはリザーブド）を配置するのが鉄則として問われる。
- **実務での使い方**: プロダクション（本番）環境のEMRにおいて、絶対に落ちては困るマスターノードと
- **副業での需要**: ★★☆（確実なSLA（サービスレベル合意）を満たすためのインフラ手配として、クラ

Spotインスタンスとデータ損失リスクの完全回避（タスクノード専用）

- **概要**: AWSの余剰EC2リソースを入札して利用する、最大90%のコスト削減が可能な破格のインスタン
- **試験ポイント**: 「コストを劇的に下げつつ、中断による**データ損失を防ぎたい**」という要件に対し、「
- **実務での使い方**: 夜間のバッチETL処理やモデルの再学習などで、「一時的に大量の計算リソース（手足
  ScalingグループのSpotインスタンスで大量に横並べ（スケールアウト）する黄金構成（ベストプラクテ
- **副業での需要**: ★★★（AWS FinOps（クラウドコスト最適化コンサルティング）において最も効果が大

SageMaker Model Registry Collections (階層的な組織化)

- **概要**: SageMaker Model Registry内に存在する多数の「モデルグループ」を、さらに「コレクション（
- **試験ポイント**: 「既存のモデルアーティファクトの構造や参照関係を一切壊すことなく、より上位のレ
- **実務での使い方**: 大規模なML組織において、「CV（画像認識）」や「NLP（自然言語）」といった大
- **副業での需要**: ★★☆（エンタープライズ規模のMLOps基盤構築において、後から増え続けるモデルの

SageMaker Model Registryのモデルグループ（制約）

- **概要**: 推論モデルそのもの（およびそのバージョン）を管理する基本単位。同じ目的を持つモデルのバ
- **試験ポイント**: 既存のモデルグループをそのまま切り離して「別のモデルグループを作って整理する（移
- **実務での使い方**: 「商品レコメンドモデル（v1, v2, v3…）」のような1つの推論タスク単位のバージョン
- **副業での需要**: ★★★（MLパイプラインの最後の着地点であり、承認ワークフローと連携するCI/CD設

カスタムタグの限界（整理機能として）

- **概要**: モデルパッケージに対して、任意のキーと値（例：`Project=Marketing`）を付与できる機能。
- **試験ポイント**: 検索やフィルタリング（発見可能性の向上）には役立つが、「階層的な組織構造を作っ
- **実務での使い方**: 請求処理のコスト配分（Cost Allocation Tag）や、誰が作ったモデルか（Ownerタグ）
- **副業での需要**: ★★☆（IaCや自動化パイプラインにおいて「タグベースのアクセス制御」や「コスト管

SageMaker ML Lineage Trackingの用途と限界

- **概要**: デプロイされたモデルが「過去にどのデータセットで、どのアルゴリズムで、どのように学習され
- **試験ポイント**: 「学習からデプロイまでの関連性を追跡し、モデルの監査性を高める機能」であり、**「**
- **実務での使い方**: 金融や医療など説明責任（アカウンタビリティ）が強く求められる領域において、数
- **副業での需要**: ★★☆（企業コンプライアンス要件に合わせた「監査可能なML基盤」を構築する案件に

モデルの発見可能性（Discoverability）

- **概要**: MLの規模が拡大（スケール）し、社内に何千ものモデルが乱立した際、「すでに誰かが似たよう
- **試験ポイント**: これをスケールさせて向上させることがModel Registry本来のアプローチであり、特に「階層的な組織化での発見可能性向上 = Collectionsの使用」がセオリーとして出題される。
- **実務での使い方**: 車輪の再発明（わざわざ似たモデルをゼロから学習し直す無駄なGPUコスト）を防ぐ
- **副業での需要**: ★★★（全社AI基盤開発（プラットフォームエンジニアリング）のリードアーキテクト

Amazon SageMaker Autopilot（自動機械学習・AutoML）

- **概要**: テーブル（構造化）データと「予測したいターゲット列」を指定するだけで、自動的にデータの
- **試験ポイント**: 「**最小限の開発作業（運用オーバーヘッド）で**、目的変数の予測可能性を評価したい」
- **実務での使い方**: 顧客から「とりあえずこの顧客データから退会ユーザーを予測できるかサクッと調べ
- **副業での需要**: ★★★（データサイエンスの深いコーディングスキルがなくても高度な機械学習モデルを

EC2とカスタムスクリプトにおけるスクラッチ開発の制約

- **概要**: EC2インスタンスを立てて、Python環境を自力で構築し、scikit-learn等を用いてゼロからモデル構築コードを書くアプローチ。
- **試験ポイント**: 要件に**「最小限の開発作業」**や**「運用オーバーヘッドの削減」**とあった場合、EC2のOS
- **実務での使い方**: 既存のオンプレ環境のレガシーコードを一旦そのままクラウドで動かしたい（リフト
- **副業での需要**: ★☆☆（逆に、この手作りレガシー環境をSageMaker等に移行（モダナイズ）する保守

Amazon Macieの制約（機械学習の用途相違）

- **概要**: S3バケット内に保存されている「クレジットカード番号」や「氏名」などの機密データ（PII）を
- **試験ポイント**: 裏で学習モデルを使っているため名前が挙がるが、あくまで「機密データの発見・保護
- **実務での使い方**: 金融などコンプライアンス要件が厳しいシステムにおいて、データレイク（S3）上に
- **副業での需要**: ★★☆（データガバナンス構築支援において、AWSのセキュリティベストプラクティスの

Amazon Bedrockの用途と限界（LLM vs 構造化データ）

- **概要**: ClaudeやLlama、Titanなどの強力な大規模言語モデル（LLM）や基盤モデルをAPI経由で簡単に
- **試験ポイント**: 「テキストの要約や生成（自然言語処理）」には最強だが、「CSVなどの構造化データ
- **実務での使い方**: チャットボットや社内ドキュメント検索（RAG）、要約タスクなど、「言葉（自然言
- **副業での需要**: ★★★（生成AI案件は現在最も単価が高いが、クライアントの要件が「LLMで解決すべ

モデルの予測可能性評価（評価メトリクス）

- **概要**: 用意したデータセットの中に「本当に何かしらの法則（パターン）が存在し、未来のデータを当
- **試験ポイント**: 予測の可能性を測定するには、必ず「トレーニングとメトリクスの算出」が必要となる。
- **実務での使い方**: PoC（概念実証）フェーズ終了時のマイルストーン。「AUCが0.8を超えたので実運用
  go判断の説得材料（基準）として使う。
- **副業での需要**: ★★★（モデルを作ること以上に、そのモデルが「ビジネス要件を満たす精度に達して

MLデータ準備の黄金ワークフロー（スキーマ推論 → データ加工）

- **概要**: 機械学習モデルのトレーニングに使用するデータセットを準備する際の王道プロセス。
- **試験ポイント**: 生データ（CSV等）にはラベルや定義が存在しないことが多いため、必ず**「①データ構**
- **実務での使い方**: S3に投げ込まれた生の汚いログデータを、機械学習アルゴリズムが食える綺麗なテー
- **副業での需要**: ★★★（MLエンジニアの仕事の8割はデータ前処理であるため、この上流側の「データ

AWS Glue クローラー（スキーマの自動推論）

- **概要**: S3に置かれた大量のファイル群（CSVやJSON）を這い回り（スキャンし）、中身を読んで「列名
  Data Catalogにメタデータとして登録する機能。
- **試験ポイント**: 「ラベル（列定義）が付いていない生のデータから『スキーマを自動で推論』したい」
- **実務での使い方**: 新しいデータソースが追加された際に、とりあえずクローラーを走らせてカタログ化
- **副業での需要**: ★★★（データ基盤構築・ETL案件における「データソースの可視化・カタログ化」の

AWS Glue DataBrew（ノーコード・データプレパレーション）

- **概要**: コード（PythonやSQL）を一切書くことなく、視覚的（GUI）なインターフェースでデータの欠
- **試験ポイント**: 「**コードを書かずに（視覚的なインターフェースで）**、MLのトレーニングに適した形へ
- **実務での使い方**: エンジニアリングスキルの高くないビジネス部門（アナリストやドメインエキスパート
- **副業での需要**: ★★☆（データ民主化・セルフサービスBI/AI基盤導入コンサルティングにおいて、プロ

Amazon Athenaにおけるスキーマ推論機能の限界

- **概要**: S3に対してSQLクエリを実行するサーバーレス検索エンジン。
- **試験ポイント**: 検索は強力だが、**「Athena自身には事前のスキーマ定義を『ゼロから自動で推論（推**
- **実務での使い方**: Glueクローラーが作ってくれたカタログ（メタデータ）を利用して初めて、「Athena
- **副業での需要**: ★★☆（Athenaで検索できない（No tables found等）というトラブルシューティングに

Amazon SageMaker バッチ変換ジョブと用途の明確化

- **概要**: 大量のデータに対して、「すでに学習済みのモデル」を使って一括で予測結果を出す（推論する）
- **試験ポイント**: あくまで「推論（テストを解かせる）」ための機能であり、**「モデルの学習前に行うデ**
- **実務での使い方**: 夜間にS3に溜まった100万件のユーザーデータに対して、一斉に「明日の離脱確率」を
- **副業での需要**: ★★☆（「リアルタイム推論（API・エンドポイント）」と「オフライン推論（バッチ変

大規模MLワークフローとAmazon SageMaker Pipelines

- **概要**: データ処理から学習、評価、デプロイまでの複数のステップを直列/並列に連結し、自動化された
- **試験ポイント**: 「5TBを超える大規模データ」や「数時間かかる複雑なNLP処理」を含む、**複数のステ**
  Pipelinesが絶対的な大正解（ベストプラクティス）となる。EventBridgeと直接連携してスケジュール
- **実務での使い方**: スクラッチで作った複数のSageMaker Processingジョブ（前処理部分）とTrainingジョブ（学習部分）を連結し、本番環境で「毎週日曜日の深夜に最
- **副業での需要**: ★★★（MLOpsエンジニアの案件において、このSageMaker Pipelinesをゼロから設計・実装できる人材は非常に少なく、高単価（時給5,000円〜）案件を安定して

AWS Lambda（およびStep Functions）の限界（15分の壁）

- **概要**: AWSインフラ全般の自動化によく使われる構成。Step Functions（オーケストレータ）からLambda関数（サーバーレス実行環境）を呼び出す。
- **試験ポイント**: この組み合わせは**「Lambda関数の15分という実行時間上限（およびメモリ最大10GB**
  Pipelines等を使う。
- **実務での使い方**: S3に画像が置かれた時にサムネイルを作るなどの、ちょっとしたトリガー用の軽量ス
- **副業での需要**: ★★☆（「この要件ならLambdaではなく別の実行基盤を使うべき」と、上限仕様を見

SageMaker Data Wranglerの限界（巨大バッチ処理不可）

- **概要**: GUI上でポチポチとデータ加工ができるインタラクティブなUIツール。
- **試験ポイント**: インタラクティブな操作には向いているが、**「5TBを超える大規模なデータセットの処**
- **実務での使い方**: あくまでデータサイエンティストが「手元で10GB程度のデータをとりあえずサクッと
- **副業での需要**: ★★☆（データ整備の初期フェーズでのみ重宝されるが、本番パイプライン（自動化）

SageMaker ノートブックの限界（本番自動化への不適合）

- **概要**: データ分析者が手動でセルを実行して実験・試行錯誤するためのJupyter Notebook環境。
- **試験ポイント**: EventBridge等でノートブック全体をスケジュール実行する機能自体は存在するが、「複
- **実務での使い方**: 「手動で実験する場所（開発環境＝Notebook）」と「自動でパイプラインが回る場所
  Pipelinesに移植する、というフローを徹底する。
- **副業での需要**: ★★☆（クライアントが「担当者がNotebookを毎日手動実行して運用している」という

Amazon SageMaker 大局的ツールの用途マッピング（4大機能）

AWS試験および実務において、用途（フェーズ）ごとに専用ツールを切り分ける要件が頻出します。
- **Data Wrangler**: 学習前のデータ準備・可視化 - **Clarify**: バイアス検出・モデルの説明性証明

- **Debugger**: 学習中（トレーニング中）の異常検知 - **Model Monitor**: デプロイ後（推論中）の継続的な監視

Amazon SageMaker Data Wrangler（データ準備・品質診断）

- **概要**: データのインポート、クリーニング、変換を一つのGUIインターフェースで実行できるデータ準備
- **試験ポイント**: 300以上の組み込み変換機能に加え、**「データ品質とインサイトレポート」を自動作成**
  Wranglerが大正解。
- **実務での使い方**: 分析の最初期において、「このデータセット、そもそも使い物になるのか（欠損値だ
- **副業での需要**: ★★☆（Glue DataBrewと同様にプログラミングレスなデータ準備が可能だが、こちら

Amazon SageMaker Clarify（バイアス検出・説明可能性）

- **概要**: 「モデルに偏見（バイアス）が含まれていないか」と「なぜその予測が出たのか（説明可能性：
- **試験ポイント**: **「トレーニング前とトレーニング後の両方でバイアスを検出する」**点や、**「SHAP値や**
- **実務での使い方**: 銀行のローン審査モデルなどで、「性別や人種によって審査結果に不当なバイアスが
- **副業での需要**: ★★★（AIに対する法規制が年々厳しくなる昨今、モデルの「説明責任（AIガバナンス）

Amazon SageMaker Model Monitor（本番デプロイ後の監視）

- **概要**: すでに本番環境にデプロイされたエンドポイントを「継続的」に見張り続ける番人サービス。
- **試験ポイント**: **「本番環境に送られてくる入力データの分布が、学習時の分布から徐々にズレていない**
- **実務での使い方**: 「AIはデプロイした瞬間から精度が劣化し始める」という前提に立ち、Model Monitorでドリフト（分布変化）を検知した際にアラートを鳴らし、前述のSageMaker Pipelinesをキックして自動で再学習を回す「継続的学習環境（CT）」のトリガーとして構築する。
- **副業での需要**: ★★★（MLOpsの最終段階である「モデルの経年劣化対策」を自力で設計・実装・運用

Amazon SageMaker Debugger（学習中プロセスのデバッグ）

- **概要**: モデルがまさに「トレーニングされている最中」のメトリクスやリソースを監視するツール。
- **試験ポイント**: **「勾配消失（Vanishing Gradient）や勾配爆発、オーバーフィッティング」**といった
- **実務での使い方**: ディープラーニングのモデルにおいて、1回の学習に何百ドルもかかるような高額・長
- **副業での需要**: ★★☆（FinOps（コスト最適化）の一環として、「無駄な失敗トレーニングジョブのコ

SageMaker PipelinesとModel Registryの統合（自動承認ワークフロー）

- **概要**: MLワークフローの自動化機能（Pipelines）と、モデルのバージョン管理機能（Model Registry）を連携させ、CI/CDパイプライン上でモデルの推論精度をチェックし、一定基準を満たした
- **試験ポイント**: **「トレーニングされたモデルが特定の精度基準を満たした場合のみデプロイし、そうで**
  Registryの承認ステータスを変更（SDK等でPendingManualApprovalからApprovedへ更新）する」ア
- **実務での使い方**: RMSEが一定値を下回るなど精度の向上が見られた優良モデルのみを「Approved（承
- **副業での需要**: ★★★（MLOps基盤構築案件において、「精度が落ちたゴミモデルが誤って本番環境に

SageMaker Model Registryの承認ステータスによるデプロイ制御

- **概要**: Model Registry内の各モデルバージョンに付与されるステータスフラグ（`PendingManualApprova`
  `Approved`, `Rejected`）。
- **試験ポイント**: 「承認されていないモデルが本番環境にデプロイされるのを防ぎたい」という要件に対
- **実務での使い方**: AWS SDKやBoto3を用いて、`update_model_package`
  APIでステータスをプログラム制御することで、外部の承認システム（ServiceNowやJiraなど）と連動し
- **副業での需要**: ★★☆（CI/CDパイプラインと顧客の社内承認プロセス・フローを結合させるインテグ

SageMaker Experimentsの用途と限界（承認ワークフロー非対応）

- **概要**: データサイエンティストが「どのパラメータで学習したときが一番精度が良かったか」を後から比
- **試験ポイント**: 「実験の比較や記録」には大正解だが、**「モデルの承認ワークフローやデプロイを制御**
- **実務での使い方**: 探索的フェーズにおいて、Excelでハイパーパラメータの手動管理をするのをやめさせ、
- **副業での需要**: ★★☆（MLflowなどと同様の実験管理のデファクトスタンダードとして、モデル開発チ

SageMaker ML Lineage Trackingの用途と限界（承認ワークフロー非対応）

- **概要**: モデルの生成過程（どのS3データを使って、どのコンテナイメージで、どの学習ジョブで生成され
- **試験ポイント**: 「モデルの監査性向上や再現性の確保（証拠保全）」には大正解だが、**「承認ステータ**
- **実務での使い方**: 情報漏洩などのインシデント発生時や法務監査が入った際に、「このAIモデルは問題の
- **副業での需要**: ★★☆（金融や医療など、監査要件が極めて厳しいエンタープライズクライアントのAIエ

SageMaker Model Monitorの用途と限界（承認判定への不適合）

- **概要**: デプロイされた本番エンドポイントの入力データや推論結果を「継続的」に監視するツール。
- **試験ポイント**: **「デプロイ後（推論フェーズ）」**の監視には大正解だが、**「デプロイ前（学習終了直後）**
  Monitorを選ぶのは時系列的な不正解（アンチパターン）となる。
- **実務での使い方**: 前述の通り、本番稼働後の「データドリフト」などを検出し、モデルの再学習タイミ
- **副業での需要**: ★★★（MLOpsにおける継続的学習（CT）ループの始点となるため非常に重要）

モデルドリフト（性能劣化）の2つのメカニズム

- **概要**: 本番環境稼働後に、入力データの傾向や社会情勢が変化することで、AIモデルの予測精度が徐々に
- **試験ポイント**: モデルの劣化要因として、「**データドリフト**（入力されるデータの分布時系列が変わる
- **実務での使い方**: Eコマースの需要予測モデル等において、新型コロナウイルスのような劇的な環境変化
- **副業での需要**: ★★★（「AIは作って終わりではない」という運用設計（MLOps）としての価値をクラ

SageMaker Clarifyによる特徴量アトリビューション監視（本番環境）

- **概要**: Clarifyの機能を本番エンドポイントに適用し、「過去（学習時）」と「現在（本番）」で、モデル
- **試験ポイント**: **「特徴量の重要度がどう変わったか（特徴量アトリビューションドリフト）を本番環境**
- **実務での使い方**: 「学習時は『年齢』が一番予測に効いていたのに、最近の本番データへの推論時には
- **副業での需要**: ★★☆（単なる「データの分布が変わった」だけではなく、「予測ロジック自体への影

SageMaker Debuggerの限界（本番推論への不適合再掲）

- **概要**: モデルのトレーニングプロセス（学習中のテンソルデータ等）をリアルタイムで監視・分析・デバ
- **試験ポイント**: 勾配消失や過学習（オーバーフィッティング）の検出には大正解だが、**「本番環境にデプ**
  Monitor」や「Clarify」を使う。
- **実務での使い方**: あくまで「AIを作るための工場（トレーニングパイプライン）」の中でのみ機能させる
- **副業での需要**: ★★☆（トラブルシューティング能力として、トレーニング起因のバグ（NaNの発生など

セマンティック検索（意味ベースの検索）とキーワード検索の違い

- **概要**: 単純な単語の完全一致（キーワード検索）ではなく、「りんご」と「MacBook」の違いや、「購
- **試験ポイント**: 後述するRAGを構築するためには、「キーワード検索」ではなく「意味的に似ている文
- **実務での使い方**: ユーザーが「パスワードを忘れた」と検索した際に、「パスワード」という単語がタイ

Retrieval Augmented Generation（RAG）アーキテクチャ

- **概要**: 大規模言語モデル（LLM）の「ハルシネーション（もっともらしい嘘）」を防ぐため、企業内の
- **試験ポイント**: LLMを自前で微調整（ファインチューニング）するよりも、**「コストを抑えて最新かつ**
- **実務での使い方**: 「社内ヘルプデスク・チャットボット」を作る際、LLM自体に社内情報を学習させる
- **副業での需要**: ★★★（現在最も需要と単価が高い生成AI案件の中核であり、このRAGの設計・実装が

Amazon KendraによるRAGの高速構築（最小限の開発）

- **概要**: 機械学習を活用したフルマネージド型のインテリジェント（セマンティック）検索プラットフォー
- **試験ポイント**: 「S3内の大量のPDF等のドキュメントを用いて、**最小限の開発作業で**セマンティック検
- **実務での使い方**: S3バケットをデータソースとしてKendraコネクタに指定するだけで、S3内のPDFやW
- **副業での需要**: ★★★（自前でOpenSearch等のベクトルDB領域を設計・運用するスキルがなくても、

AWS Glue および SageMaker Feature Storeの限界（セマンティック検索非対応）

- **概要**: GlueはデータのETL（抽出・変換・ロード）ツール、Feature
  Storeは機械学習の特徴量（テーブルデータ）を保存・提供するデータベース。
- **試験ポイント**: どちらも「SQLを使った構造化データ（表データ）の処理」には長けているが、**「文章**
- **実務での使い方**: これらの堅牢なツールはあくまで従来型の機械学習（需要予測や不正検知など）のパ

Amazon Textractの限界（セマンティック検索非対応）

- **概要**: スキャンした請求書の画像やPDFから、文字（テキスト）や表のデータをOCR（光学文字認識）
- **試験ポイント**: 「ドキュメントからテキストを抽出する」機能には極めて優れているが、**「抽出したテ**
- **実務での使い方**: Textractで画像内の文字をテキストデータ化し、それをS3に保存した上で、**その後段の**

ベースライン分析とSageMaker Model Monitor（運用監視の起点）

- **概要**: 本番環境にデプロイする前に「正常時のテスト成績（ベースライン）」を記録し、本番稼働後の実
- **試験ポイント**: デプロイ後の推論パフォーマンス低下を検知するためには、必ず**「事前にベースライン**
  Monitorで評価するプロセスが問われる。

- **実務での使い方**: 「デプロイ直後のモデルはF1スコアが0.85だった」という基準（ベースライン）をMo
  Monitorに登録し、「直近1週間の本番データでのF1スコアが0.78まで落ちた」際にCloudWatchアラー
- **副業での需要**: ★★★（顧客に「いつAIを再学習させるべきか」をデータに基づいて自律的に判断する

コンセプトドリフト（ルールの崩壊）と再学習のトリガー

- **概要**: 時間の経過とともに、市場環境やユーザー行動の「社会的なルール・前提（特徴量と目的変数の
- **試験ポイント**: 単に入力データの分布が変わるデータドリフトに対し、コンセプトドリフトは**「ルール**
- **実務での使い方**: これを放置すると「古い常識で予測し続ける無能なAI」になってしまうため、前述のM
  Monitorからのアラートを起点に、データサイエンティストが介入してモデルを作り直す（コンセプト

クラス不均衡データに対するF1スコアの優位性

- **概要**: 不正検知（正解が全体の1%未満など）の「極端に偏ったデータセット（クラス不均衡）」におい
- **試験ポイント**: 「クラス不均衡があるデータセットで、性能が低下していることを検出したい」という要
- **実務での使い方**: 99%が正常な取引のデータに対して、全て「正常です」と答えるだけのスパムAIを作
- **副業での需要**: ★★☆（「精度は90%超えているからAIの調子が良い」と誤認しているクライアントに対

SageMaker ClarifyとLambdaによるオンデマンド・バイアス監視

- **概要**: 「モデルの特定の特徴量（人種や性別など）に対する予測が、本番環境で偏ってきていないか（
- **試験ポイント**: 「運用オーバーヘッドを最小限に抑えつつ、オンデマンド（任意のタイミングや定期実行
  LambdaからSageMaker Clarifyジョブ（Processingジョブ）を呼び出す」構成が完全な正解とな
- **実務での使い方**: EventBridgeのスケジュール（毎日深夜等）でLambdaをトリガーし、Boto3でClarify
- **副業での需要**: ★★★（手動で監視する運用コストを極限まで減らす「自動化アーキテクチャ」の設計

SageMaker Model Monitorの限界（バイアス検出非対応）

- **概要**: デプロイされたモデルのデータ分布の変化（データドリフト）や推論精度の低下（モデル品質の
- **試験ポイント**: データの品質偏差は監視できるが、そのままでは**「バイアスや公平性の問題（人種・性**
  Monitorを選ぶのは機能のアンチパターン（不正解）となる。バイアス検知には必ず前述のClarifyを選
- **実務での使い方**: 要件が「単なる精度の劣化」なのか「社会的偏見（公平性）の崩れ」なのかをヒアリ
  Monitor、後者ならClarifyを利用するようアーキテクチャを決定する。

AWS Glue Data Qualityの限界（モデル監視非対応）

- **概要**: S3などに保存されたデータに対して、「NULLが多すぎないか」「異常な値が入っていないか」
- **試験ポイント**: データ品質の評価には大正解だが、**「機械学習モデルのバイアスドリフトを監視する機**
  Data Qualityを選ぶのは不正解となる。
- **実務での使い方**: AIにデータを食わせる前の「上流側（データレイク基盤）」において、汚いデータがM

SageMaker ノートブックによる自動化の制約とアンチパターン

- **概要**: データサイエンティストが手動でセルを実行して検証を行うJupyterノートブック環境。
- **試験ポイント**: ノートブック内でコードを書き、その中でClarifyジョブを呼び出すことは技術的には可能

- **実務での使い方**: コードのテストが終わったら、ノートブックの役割は終了とし、その本番コードをLa
  Processingジョブに「移植」して自動化させる、というベストプラクティスを遵守する。

Amazon Kinesis Data Streamsとリアルタイム異常検知

- **概要**: 大量のログやIoTセンサーデータなどをミリ秒単位のリアルタイムで継続的に取り込み、後段の分
- **試験ポイント**: 「ストリーミングデータに対してリアルタイムで異常検出を実行したい」という要件に対
  Managed Service for Apache Flinkと組み合わせる構成が王道パターンとして頻出する。
- **実務での使い方**: クレジットカード決済のトランザクションログなどをリアルタイムに受け取る窓口（
- **副業での需要**: ★★★（AWSにおけるデータストリーミングアーキテクチャの必須サービスであり、バ

Amazon Managed Service for Apache Flink（旧Kinesis Data Analytics）と異常検知

- **概要**: Kinesis等から流れてくるリアルタイムデータを、標準のSQLクエリ等を使用して分析・変換でき
- **試験ポイント**: 最大の目玉は**「RANDOM_CUT_FORESTという異常検出の組み込み関数（SQL）」**を
- **実務での使い方**: Kinesis Data Streamsから流れてくるWebのアクセスログなどに対し、このサービスの
  `RANDOM_CUT_FOREST` 関数を叩くだけで、「いつもと違う異常スパイク」が含まれていた際にAnomaly
  Scoreを弾き出し、即座にブロックやアラートへ流す仕組みを作る。
- **副業での需要**: ★★★（SageMakerを使わずにSQLだけで高度な機械学習的異常検知を実装できるため

SageMakerエンドポイントによるストリーミング処理の限界

- **概要**: 通常の機械学習プロセス（モデルを自前で学習させ、エンドポイントAPIとして本番環境にデプロ
- **試験ポイント**: **「ストリーミングデータの異常検知を最小限のオーバーヘッドで実現したい」**という要件
- **実務での使い方**: この要件でSageMakerの自前エンドポイントを立てると、「モデルの再学習の手間」
  Flink）のみで済む要件に、重厚なカスタムモデル（SageMaker）を持ち込むのはアンチパターン（オー

運用オーバーヘッドの最小化という最重要評価軸

- **概要**: AWS認定試験全般における「ベストプラクティス（正解）」を見極めるための強力なキーワード
- **試験ポイント**: 要件に「運用オーバーヘッドを最小限にする」と書かれていた場合、**①サーバーレス/マ**
- **実務での使い方**: 顧客にシステムを納品した後、保守フェーズにおいて「顧客側の非エンジニアでも運用
  FlinkやAutopilotなど）で要件を満たせないかを最優先で検討する（車輪の再発明をしない）。
- **副業での需要**: ★★★（「技術的に高度なオレオレAIシステム」を作るよりも、「誰もメンテしなくて済

SageMaker Data Wranglerの2つのデータインポート方法

- **概要**: Data Wranglerでデータを読み込む際のアプローチ。「ダイレクト接続」と「カタログ接続」の2
  Wranglerがインポートできるのは最大1,000列（カラム）までのデータセットである点に注意。
- **試験ポイント**: **「ダイレクト接続」**はS3等のデータソースに直接アクセスし、「接続したその瞬間のス
  Glueデータカタログを介して接続し、常に最新のメタデータ（スキーマ情報）に基づいて動的にデータ
- **実務での使い方**: サクッと1回だけデータを綺麗にしたい探索的データ分析（EDA）の時は「ダイレクト

カタログ接続の強み（AWS Glue連携）

- **概要**: AWS Glueデータカタログを「メタデータの中央管理システム」として介在させる接続方法。
- **試験ポイント**: 「データソースのスキーマ構成が変わっても自動で最新のデータ構造を読み込みたい」
- **実務での使い方**: S3、Redshift、Snowflakeなど物理的に保存場所が異なる複数のバックエンドソースを Wrangler上でSQLベースのクエリを書いて透過的にアクセスする際に用いる。
- **副業での需要**: ★★☆（様々なSaaSやDBに入り乱れたデータを「論理的に一元管理」するデータファ

AWS Glueデータカタログ（クラウドの羅針盤）

- **概要**: AWS上の「どこに・どんな構造の（スキーマの）データがあるか」を全て記録しておく、データ
- **試験ポイント**: データ実体そのものを保存するのではなく、**「クローラーをスケジュール実行してS3等**
- **実務での使い方**: S3に生データを置いた後、まずはGlueクローラーを走らせてこのカタログ（目次）を Spectrumなどから「あのデータどこにある？」と聞かれた際に、このカタログが案内図として機能し
- **副業での需要**: ★★★（AWSデータエンジニアリングの「絶対的なハブ（羅針盤）」であり、このメタ

S3のパーティション化とAmazon Athenaのパフォーマンス最適化

- **概要**: S3に保存するデータを `s3://bucket-name/year=2024/month=01/day=15/` のように、日付や地域等の属性ベースのフォルダ階層（プレフィックス）で論理的に分割して保存する
- **試験ポイント**: 「Amazon Athenaのサーバレスクエリを高速化しつつ、コストを削減したい」という要
- **実務での使い方**: 「過去3日間のデータだけを分析したい」という場合、パーティション化されていれば
- **副業での需要**: ★★★（顧客のクラウドコストを削減する「FinOps」的なアプローチとして、ただS3と

S3ライフサイクルポリシーによる運用オーバーヘッドとコストの最小化

- **概要**: 「作成から30日経過したログ」などの条件に基づいて、自動的にS3内のデータをより安価なスト
- **試験ポイント**: 前述のS3のパーティション構造と組み合わせることで、「30日を超える古いパーティシ Glacier Flexible Retrieval等）に移行してコストを削減する」操作を、**「カスタムコードを書かずに自動**
- **実務での使い方**: 機械学習の推論ログやWebアクセスログは「直近1ヶ月は分析で頻繁に使うが、それ以

S3 Glacier Flexible Retrievalの最適なユースケース

- **概要**: S3 Standard（標準）ストレージよりも大幅に保管コストが安い代わりに、データを取り出す（後
- **試験ポイント**: 「データへのアクセス頻度は低い（または不要だ）が、いざという時には数分〜数時間
- **実務での使い方**: 監査ログや、数年前の使用済み学習データなど、「普段は誰も見ないが、法務監査が

SageMakerのコンテナ間トラフィック暗号化（分散トレーニング時のセキュリティ）

- **概要**: 複数のインスタンス（ノード）を使って大規模な分散トレーニングを行う際、各々のコンテナ間
- **試験ポイント**: 分散トレーニングジョブのノード間通信は、**デフォルトでは暗号化されていない**。その
- **実務での使い方**: 医療データや金融データを扱う極めて厳格なセキュリティ要件（PCI DSSやHIPAA等）が求められるプロジェクトにおいて、AWS内部のVPCネットワークであろうとも通信
- **副業での需要**: ★★☆（エンドポイントのSSL通信だけでなく、バックエンドでの「インスタンス間暗号

SageMakerのネットワーク分離（完全なる隔離）

- **概要**: コンテナからのアウトバウンド（外部への）ネットワーク呼び出し機能を**完全に無効化（遮断）**
- **試験ポイント**: VPCすら介さず完全に隔離されるため、「インターネットや、S3を含むその他のAWSサ
- **実務での使い方**: 外部に絶対に流出してはいけない機密学習データを扱う際、サードパーティの不正な

セキュリティグループとコンテナ間暗号化の併用（UDP 500等の許可）

- **概要**: AWSの各インスタンスに対する「ステートフルなファイアウォール」機能。送受信するポートやI
- **試験ポイント**: セキュリティグループ自体は「フィルタリング機能」であり、「暗号化機能」は持ってい
- **実務での使い方**: 「どうしてトラフィック暗号化をOnにしたらジョブがエラーで止まるんだ？」という

SageMaker リアルタイム推論エンドポイント（低遅延・高可用性の最適解）

- **概要**: ミリ秒単位の低レイテンシー（遅延）で、かつHTTP/HTTPS経由で推論リクエストを捌くためフ
- **試験ポイント**: 「予測不可能なトラフィックの変化に自動で対応しつつ、運用オーバーヘッドを最小限に
- **実務での使い方**: ユーザーがスマホアプリのボタンを押した瞬間に「AIの判定結果」を返すような、スピ
- **副業での需要**: ★★★（「AIは作れたけどどうやってWebアプリ側のシステムと繋ぐの？」というクライ

Amazon ECSによる自前コンテナ運用のアンチパターン

- **概要**: DockerコンテナをAWSのマネージドオーケストレーションサービス。
- **試験ポイント**: リアルタイム推論APIを自前でECSクラスター上に立てることは可能だが、**「予測不可能**
- **実務での使い方**: 既に全社的なシステムがECSでガチガチに統一されており、「どんなワークロードも

Amazon EKS（Kubernetes）とSageMaker Operatorのアンチパターン

- **概要**: 大規模なコンテナ群を管理するKubernetes（K8s）のマネージドサービス。
- **試験ポイント**: EKSとSageMaker Operatorを使って推論エンドポイントを立てるアーキテクチャも存在
- **実務での使い方**: グローバル規模の巨大プラットフォームで、複数クラウド（マルチクラウド）を跨いで

高可用性要件におけるスポットインスタンス（Spot Fleet）の罠

- **概要**: AWSの余剰コンピューティングリソースを格安（最大90%オフ）で借りられる仕組みだが、AWS
- **試験ポイント**: 「高可用性（いつでも必ず落ちずに応答できる状態）」が求められるリアルタイム推論
- **実務での使い方**: スポットインスタンスは「途中で中断されても後でやり直せばいいバッチ処理」や「
  DemandインスタンスかReservedインスタンスを使用する。

Amazon Comprehendと最短の自然言語処理（NLP）

- **概要**: テキストデータから「感情分析（ポジティブ・ネガティブ等）」「エンティティ抽出」「キーフレ
- **試験ポイント**: 「テキストデータの感情分析を**最短時間で（あるいは最小の労力で）**実装したい」とい
- **実務での使い方**: 自社のコールセンターに寄せられた「顧客からの問い合わせメール」や「アンケート
- **副業での需要**: ★★★（クライアントの「AIでうちのテキストデータを分析してみたい」というふわっ

AIマネージドサービス vs カスタムモデル開発の評価軸

- **概要**: 「AWSが既に作って提供しているAI API（Comprehend等）」と、「SageMaker等を使って自分
- **試験ポイント**: 要件に「最短時間で」「最小の労力で」と書かれている場合、**「ナイーブベイズ分類器や**
- **実務での使い方**: ビジネス上の課題が「一般的な感情分析や物体検出」の範疇に収まるなら素直にマネ

Amazon Rekognitionの限界（テキスト感情分析非対応）

- **概要**: 画像や動画から「物体」「顔」「不適切なコンテンツ」などを検出する、コンピュータビジョン
- **試験ポイント**: 「人の顔画像からの感情分析（笑っている、怒っている等）」機能はあるが、**「テキス**
- **実務での使い方**: 店舗の防犯カメラ映像をRekognitionに流し込んで「来店客の年齢層や表情（感情）」

Amazon Redshiftの動的データマスキング（最小権限の原則の実装）

- **概要**: データベースに対するクエリ実行時に、機密データ（クレジットカード番号やメールアドレスなど
- **試験ポイント**: 「ソース（元の）データを変更せず、また『匿名化されたデータ自体』をストレージに特
  `MASKING POLICY`文を使用してポリシーを作り、それをテーブルの列にアタッチするだけで、アクセスす
- **実務での使い方**: データサイエンティストには個人情報がマスキングされた状態のテーブルを見せ、経営
- **副業での需要**: ★★★（金融や医療等のセキュリティ・コンプライアンス要件が厳しいエンタープライズ

マテリアライズドビューによるマスキングのアンチパターン

- **概要**: クエリ結果をストレージ上に「物理的に保存」し、次回以降のクエリを劇的に高速化するための
- **試験ポイント**: マテリアライズドビューを使って「個人情報を省いた安全なビューテーブル」を作ること
- **実務での使い方**: マテリアライズドビューはあくまで「1時間に1回更新されるBIダッシュボードの集計用

AWS GlueによるETL匿名化処理の限界と運用オーバーヘッド

- **概要**: データの抽出、変換（匿名化等）、ロードを実行するフルマネージドなETLサービス。
- **試験ポイント**: GlueのジョブでPython/Sparkコードを書き、個人情報を匿名化することは可能だが、**「**
- **実務での使い方**: 外部の分析パートナー企業にデータを渡すために、完全に個人情報を削ぎ落とした「

Amazon Athenaへのアンロードとスキーマオンリードの罠

- **概要**: S3に保存されたデータに対して、読み込み時にスキーマを当てはめて（スキーマオンリードで）
- **試験ポイント**: Redshift内のデータをわざわざAthenaでコントロールしようとすると、**「定期的にS3へ**

SageMaker サーバーレス推論エンドポイント（コスト最適化の王道）

- **概要**: トラフィック（リクエスト数）に応じてサーバーリソースを自動的にスケーリングし、「リクエス
- **試験ポイント**: 最大の特徴は**「ゼロインスタンスまで完全にスケールダウンできる（アイドル時間には一**
  Concurrency）」を設定することで回避できる。
- **実務での使い方**: 「たまにバズった時だけ大量のユーザーが押し寄せるが、普段はほとんど使われない
- **副業での需要**: ★★★（実案件では「推論AIシステムを作ったはいいが維持費で赤字になるから止める」

SageMaker リアルタイム推論エンドポイントとの境界線

- **概要**: 24時間365日常に稼働する専用のインスタンス（サーバー）を用いて、ミリ秒単位の超低レイテン
- **試験ポイント**: Auto Scalingは設定できるが、最大の制約として**「ゼロ台へのスケールダウン（完全停止**
- **実務での使い方**: スマホの「顔認証決済API」や、自動運転システムと連携するような、「人間や機械か

バッチ変換（Batch Transform）と非同期推論（Asynchronous Inference）

- **概要**: 「リアルタイムな即時応答」を必要としないユースケース向けの2つの推論オプション。
- **試験ポイント**: 「バッチ変換」はリアルタイムのリクエストを受け付ける機能すらなく、S3に置かれた
- **実務での使い方**: 月次決算時に1ヶ月分の全顧客データを丸ごとAIでスコアリングする時は「バッチ変換

Amazon QuickSightの異常検出パラメータ（感度と方向）

- **概要**: 組み込みの機械学習（RCFアルゴリズム）を用いて、BIダッシュボード上で自動的にデータの異常
- **試験ポイント**: `Severity` は検出感度を表し、「Low and above（低以上）」が最も感度が高い（些細 and above」が最も感度が低い。また `Direction` は異常の出方を制御し、「All（期待値からの上振れ than expected（上振れのみ）」「Lower than expected（下振れのみ）」の3つから選べる点が問われ
- **実務での使い方**: 「売上の低迷（下振れ）だけをいち早く知りたい」場合はDirectionをLowerにし、「

機械学習の評価指標：「再現率（Recall）」の概念

- **概要**: 「本当に異常であるデータのうち、AIが正しく異常だと素通りさせずに『検出（キャッチ）』で
- **試験ポイント**: 計算式は **「真陽性（AIが当てた異常） ÷（真陽性 ＋ 偽陰性（AIが見逃した異常））」**。風邪の患者が実際には100人いるのに、AI検査キットが80人しか病
- **実務での使い方**: 「スパムメールの検知（正常なメールが迷惑フォルダに入ってもいいが、悪質な詐欺メ

異常検出における「フィルタリング」と「再現率」の絶対的な反比例関係

- **概要**: 異常検出の条件を厳しく（狭く）絞り込んだ際に生じる、機械学習におけるトレードオフ問題。
- **試験ポイント**: QuickSightのDirection設定などで「下振れ（Lower）異常のみを検出する」ように制限
- **副業での需要**: ★★★（実案件で「もっとピンポイントでアラート出してよ！」という顧客の要望に安

クラス不均衡（Class Imbalance）問題と解決策

- **概要**: 「クレジットカードの不正利用検知」や「工場の不良品検知」など、正常データが99.9%で異常
- **試験ポイント**: 不均衡なまま機械学習にかけると、AIは「全部正常と答えておけば99.9%正解できる」と **「オーバーサンプリング（SMOTEアルゴリズム等）」** や、多数派データを削る **「アンダーサンプリング」** という手法を用いることが必須となる。
- **実務での使い方**: 医療の「希少疾患の画像判定」など、“一番当てたいターゲットに限ってデータ数が極 ほぼ全ての実務プロジェクトで直面する最大の壁となる。

SageMaker Data Wranglerによる「クラス不均衡」の最短解決

- **概要**: データのクリーニングから特徴量エンジニアリングまでを視覚的（ノーコード/ローコード）に実

- **試験ポイント**: 「運用努力を最小限にしてクラス不均衡を解決したい」という要件の大正解となる。Da
  Wranglerには **「バランスデータ操作」** という機能が組み込まれており、GUI上でポチポチと設定するだ
- **実務での使い方**: 泥臭いデータ変換コードを自力で何百行も書いて
  SMOTEを実装・検証する手間を省き、フルマネージドなGUI環境でサクッと少数派データを水増しし

他サービス（Athena / DataBrew / Studio Classic）でのアンチパターン

- **概要**: クラス不均衡の解決要件において「選んではいけない（機能不足・オーバーヘッド過多）」選択肢
- **試験ポイント**:
  - **AWS Glue DataBrew**: Data Wranglerと同じ視覚的データ準備ツールだが、「SMOTEによる高度
  - **Amazon Athena**: データの分析・クエリ実行特化であり、不均衡を直す高度な前処理機能（SM
  - **SageMaker Studio Classic**: モデル開発の統合環境（IDE）であり、モデルを学習させる「前」
- **副業での需要**: ★★☆（データ準備ツールとして「Data Wrangler」と「Glue
  DataBrew」はよく似ているが、『DataBrewは一般的なデータクレンジング用、Data
  Wranglerは機械学習（クラス不均衡処理等）に特化した高度な前処理用』という境界線を理解している

SageMaker Pipelinesにおける「Callback step」の極意

- **概要**: SageMaker Pipelines（MLワークフローの自動化機能）の中で、「外部のシステム（Glue等）を
- **試験ポイント**: 「SageMakerのパイプライン処理の途中に、AWS
  Glueのデータ処理ワークフローを組み込みたい。運用オーバーヘッドを最小限にするには？」という頻
  「Callback step」を取付けるだけで、Glueの実行と完了待機を直接コントロール（同期）できるため
- **実務での使い方**: 機械学習の学習処理を走らせる直前に、「別のデータ基盤チームが管理している社内の
  ETLジョブ」をピタッと叩いて最新データを用意してもらうような、チーム間（システム間）を跨いだ

Step FunctionsやEventBridgeによる外部統合のアンチパターン

- **概要**: AWSが誇る強力なオーケストレーション（自動化）サービスたちだが、既にSageMaker
  Pipelinesを使っている場合には注意が必要。
- **試験ポイント**: 前述の要件（パイプラインにGlue処理を挟む）に対して、**「AWS
  Step Functionsを導入して全体を管理する」や「EventBridgeとLambdaを駆使してルーティングと**
  Pipelines自体に外部を呼ぶ標準機能（Callback step）があるのに、わざわざ別の自動化ツール（Step
  Functions等）やLambda関数を追加導入すると、アーキテクチャが無駄に複雑化し運用オーバーヘッド
- **実務での使い方**: AWS初心者が陥りがちな「ピタゴラスイッチ設計（要件を満たすために無駄にLambd

パイプラインの役割によるサービスの棲み分け（Glue vs SageMaker）

- **概要**: 機械学習プロジェクトにおいて「あるパイプライン（自動化の流れ）」を作る際、それが「デー
- **試験ポイント**:
  - **データインジェスション（取り込み・前処理）パイプライン**:
    S3にある巨大な生データを抽出し、クリーニング、構造化などを行う役割。この要件に対しては
    「AWS Glue」 などのETLインフラ（データエンジニアリング専用サービス）を選ぶのが大正解と
  - **モデルデプロイメントパイプライン**: 学習済みのモデルをバージョン管理（レジストリ）に登録し、
    「SageMaker Studio Classic」や「SageMaker Pipelines」
    を選ぶのが大正解となる。この両者を逆に選ぶのは完全な不正解。

- **実務での使い方**: 「データエンジニアリングチーム（Glue管轄）」と「MLOpsチーム（SageMaker管轄

Amazon SageMaker Studio Classicの世界観

- **概要**: 機械学習モデルの「開発（Jupyter環境）」「実験管理」「モデルレジストリ管理」「パイプライ
- **試験ポイント**: 単なるコードエディタではなく、機能の裏側でSageMaker Pipelines等と深く統合されているため、前述の**「モデルデプロイパイプライン（CI/CD）を作成し、**
- **副業での需要**: **★★★**（企業のAI推進室から「うちも本格的なMLOps基盤を作りたい」と相談された際 Studio Classicで全て一気通貫で管理しましょう」と提案する方が、AWSネイティブな堅牢構成として

SageMaker Notebookの限界（開発・実験用途）

- **概要**: AWS上でJupyter Notebook環境に特化して単発で提供する、古くからあるシンプルなサービス。
- **試験ポイント**: 手軽なコードの検証や「実験」には適しているが、機能が限定的であるため、**「モデル**
Classicを選ぶ。
- **実務での使い方**: 新人のデータサイエンティストがちょっとしたPythonコードを動かしたり、EDA（探

大規模言語モデル（LLM）の出力における「一貫性」の概念

- **概要**: 「同じ入力（プロンプト）」を与えた際に、LLMが「常に同じような出力」を返す能力のこと。
- **試験ポイント**: 「LLMの出力の一貫性を向上させたい（毎回ブレさせたくない）」という要件に対し、**k等を低く設定する」**のが大正解となる。※ただし、一貫性を重視しすぎると多様性や創造性が完全に
- **実務での使い方**: 「カスタマーサポートの自動応答ボット」や「社内規定の検索AI」のように、事実に

Temperature（温度）パラメータによる創造性の制御

- **概要**: LLMの出力の「ランダム性（創造性）」を制御するための最も一般的なパラメータ（通常0.0から
- **試験ポイント**: **「モデル出力の一貫性を高めよ」と問われたら、Temperatureの値を極力低く（0.1が**
- **副業での需要**: **★★★**（実案件で「うちのAI、毎回違うこと言うんだけど直せない？」という顧客のク

Top-kパラメータによる候補数の絞り込み

- **概要**: 次の単語（トークン）を予測する際、「確率が高い順から上位K個の候補のみ」に選択肢を絞り込
- **試験ポイント**: **「ランダム性を低下させ、一貫性を向上させよ」という要件に対し、Top-kの値を低く（小規模に）設定する**ことが正解となる。例えばTop-kを「1」に設定すれば、常に一番確率の高い1つの単語しか選ばれなくなり（決定論的）、Top-kを「100」にすれば100個の候補からランダムに選ばれる（創造的）ようになる。

Top-p（Nucleus Sampling）パラメータによる確率の合計絞り込み

- **概要**: 次の単語を予測する際、候補となる単語の「確率の合計値」が、あらかじめ指定した閾値P（0.0
- **試験ポイント**: TemperatureやTop-kと同様に、**値が低い（0.0に近い）ほど少確率の単語が切り捨てら**