勉強日記

日付

2026年04月07日

学習内容

SageMaker AIエンドポイントのオートスケーリング

- **概要**: SageMaker AIエンドポイントはApplication Auto Scaling with-統合されており、トラフィックに応じてインスタンス数を動的に調整する。
- **試験ポイント**: `register-scalable-target`で登録し、`put-scaling-policy`で適用.スケーラブルディメンションは`sagemaker:variant:DesiredInstanceCount`。`InvocationsPerInstanc`
- **実務での使い方**: ターゲット追跡、ステップ、スケジュールの3方式をサポート。可用性を維持しつつ、
- **副業での需要**: ★★★★★(MLOps☒ 基本機能であり、商用環境構築では必須スキル)

Application Auto Scaling vs EC2 Auto Scaling

- **概要**: Application Auto ScalingはEC2以外のマネージドサービス（SageMaker, ECS, DynamoDB等）のスケーリングに使用され、EC2 Auto ScalingはEC2インスタンス（ASG）専用である。
- **試験ポイント**: SageMakerにはEC2 Auto Scalingグループを直接アタッチできないため、Application Auto Scalingを使用する必要がある点が問われやすい。
- **実務での使い方**: SageMaker、ECS、DynamoDBなどのスケーリングはApplication Auto Scaling for一元管理する設計が標準的。
- **副業での需要**: ★★★★☆(適切なAWSリソース管理とコスト最適化の提案に役立つ)

SageMaker Neo

- **概要**: モデルをターゲットハードウェア（エッジ、クラウド）に最適化・コンパイルするサービス.推論レイテンシの改善やモデルサイズの縮小に貢献する。
- **試験ポイント**: 推論のパフォーマンス向上を目的とした「最適化」サービス.トラフィック増への対応（スケーリング）とは異なるアプローチである点に注意。
- **実務での使い方**: エッジデバイス（IoT）へのデプロイや、推論エンドポイントのスループット向上のた
- **副業での需要**: ★★★☆☆(エッジAIや推論高速化の特定ニーズに対する高度な専門性)

QuickSight 異常検出インサイト

- **概要**: Random Cut Forest(RCF)アルゴリズムを使用してデータ内の外れ値を自動検出するML機能。En Editionで利用可能。
- **試験ポイント**: 重大度（Severity）パラメータで検出感度を調整でき、「Low and above」が最も感度が高い. 方向（Direction）で「Higher than expected」「Lower than expected」「All」を設定可能。
- **実務での使い方**: ビジネス指標の急激な変化や異常なスパイクを自動的に特定し、ダッシュボード上で
- **副業での需要**: ★★★★☆(高度なダッシュボード構築案件での差別化ポイントとなる機能)

データの視覚化における変換手法

- **概要**: データの分布を調整したり、特定の値を強調/抑制するための数値変換手法（二乗、平方根、対数
- **試験ポイント**: 二乗変換（差を増幅し外れ値を強調）、平方根変換（差を圧縮し外れ値を抑制）、対数
- **実務での使い方**: データの歪みを補正して視認性を高めたり、機械学習モデルの訓練データの質を向上
- **副業での需要**: ★★★☆☆(データ分析・可視化の基礎スキルとして重要)

QuickSight 計算フィールド

- **概要**: データセット内の既存フィールドに対し、数式や関数を適用して動的に新しいフィールドを作成
- **試験ポイント**: 四則演算、べき乗、条件分岐、型変換などが可能。計算フィールドを用いてグラフの表
- **実務での使い方**: 生データにはないビジネス独自計算指標（ROI、目標達成率など）をダッシュボード
- **副業での需要**: ★★★★☆(QuickSightを用いたBI開発における必須スキル)

IAM条件キーによるSageMakerノートブック制御

- **概要**: `sagemaker:RootAccess`などのIAM条件キーを使用して、リソース作成時の各種設定を細かく制限
- **試験ポイント**: rootアクセスが「Disabled」の場合のみノートブック作成を許可する条件を設定すること
- **実務での使い方**: 組織のコンプライアンス要件に基づき、開発者が独断でroot権限を持つ環境を作成で
- **副業での需要**: ★★★★☆(セキュアなML基盤の設計・構築案件において、信頼性を高める重要スキル)

予防的ガードレール vs 事後的対応

- **概要**: IAMポリシー等で不正な操作を「未然に防ぐ（Preventative）」か、作成後のリソースを監視して
- **試験ポイント**: EventBridge+LambdaやCloudFormationによる事後監視は、一時的な権限露出やリソー
- **実務での使い方**: 基本はIAM/SCPで予防し、カバーしきれないイレギュラーな変更をConfigやEventBri
- **副業での需要**: ★★★☆☆(AWSの設計思想に基づく、高度なガバナンス設計の提案が可能)

AWS KMS (Key Management Service)

- **概要**: データの暗号化・復号に使用されるマネージドな暗号　管理サービス。
- **試験ポイント**: KMSは「データの保護（暗号化）」を目的としており、ノートブックのrootアクセス設
- **実務での使い方**: SageMakerのストレージ（EBS）やS3上のモデルデータを、顧客管理 （CMK)で暗号
- **副業での需要**: ★★★☆☆(機密データを扱う案件での暗号化実装は必須要件)

SSE-KMSによるS3データの暗号化と復号

- **概要**: AWS KMSで管理されるキーを使用してS3上のデータを暗号化する方式。復号にはKMSキーへの
- **試験ポイント**: SSE-S3（S3管理キー）との権限モデルの違いを把握すること.
  SSE-KMSでは、S3バケットへのアクセス権限（S3:GetObject等）に加え、KMSキーに対する`kms:Dec`
- **実務での使い方**:　セキュリティ要件の厳しいプロジェクトでは、SSE-
  KMSを採用し、データの書き込み（`kms:Encrypt`）と読み取り（`kms:Decrypt`）をKMSキーポリシーで
- **副業での需要**: ★★★★☆(機密データを扱う機械学習パイプライン構築における標準的なセキュリティ

SageMaker 実行ロールの権限設計

- **概要**: トレーニングジョブやモデルエンドポイントがAWSリソースにアクセスするために使用するIAMロール。
- **試験ポイント**: トレーニングデータがKMS暗号化されている場合、実行ロールにはS3アクセス権限だけ
- **実務での使い方**: 最小権限の原則に従い、特定のS3バケットと特定のCMK（Customer Managed Key）のみを許可するインラインポリシーを構成する。
- **副業での需要**: ★★★☆☆(トラブルシューティングやインフラ設定の「あと一歩」の品質に関わるスキ

S3バケットポリシー vs IAMポリシー

- **概要**: リソースベース（バケット）とアイデンティティベース（ユーザー/ロール）の制御。
- **試験ポイント**: バケットポリシーではS3リソースの制御は可能だが、KMSキーの権限（`kms:Decrypt`等
- **実務での使い方**: 全員一律の制限（HTTPS強制、特定IP拒否）はバケットポリシーで行い、個別の微細
- **副業での需要**: ★★★☆☆(AWSの設計思想に基づく、高度なガバナンス設計の提案が可能)

SageMaker Serverless Inference (サーバーレス推論)

- **概要**: AWSがインフラ管理と自動スケーリングを全て担当する推論オプション。最大6GBメモリ/6 vCPUをサポートし、使用分のみ課金される。
- **試験ポイント**: 「インフラ管理負荷を最小化したい」「従量課金にしたい」という要件への最適解。Pr Concurrency（プロビジョニング済み同時実行）を設定することで、コールドスタートを回避可能。
- **実務での使い方**: アイドリング時間が長く、リアルタイム推論エンドポイントの常時稼働がコストに見合
- **副業での需要**: ★★★★☆(コスト最適化と運用自動化の提案において非常に付加価値が高い)

推論オプション⊠⊠ 比較 (Managed vs Self-managed)

- **概要**: SageMaker Serverless（フルマネージド）とEC2 Auto Scaling/EKS（セルフマネージド）の運用上の違い。
- **試験ポイント**: EC2やEKSはインフラの管理（パッチ適用、スケーリング設定、ノード管理等）が必要
- **実務での使い方**: 運用リソースが限られる場合はServerlessやSageMakerのマネージドエンドポイントを選択し、性能上・要件上の理由がある場合にセルフマネージドを検討
- **副業での需要**: ★★★★☆(顧客の運用体制に合わせた最適なアーキテクチャ選定能力)

SageMaker バッチ変換 vs リアルタイム推論

- **概要**: 大量データを一括処理する非同期の「バッチ変換」と、リクエストに対し低レイテンシで返す「
- **試験ポイント**: バッチ変換は迅速な応答には適しておらず、予測可能で持続的な負荷に対して低レイテン + PC）が適している。
- **実務での使い方**: 定期的なレポート作成用データなどにはバッチ変換、WEBアプリ等の即時予測にはリ
- **副業での需要**: ★★★☆☆(データ処理パイプラインの全体設計に不可欠な知識)

AWSでのドリフト検出戦略 (Model Monitor vs Lambda/Debugger)

- **概要**: 本番環境でのモデル性能やデータの変化を監視するための最適なアプローチ。SageMaker Model Monitorが標準的なマネージドサービスとして推奨される。

- **試験ポイント**: Lambdaでの独自実装は、統計分析ロジックの保守コストが高く、推論レイテンシを増大
  Debuggerは「トレーニング中」の内部状態監視用であり、本番のライブデータのドリフト検出には適
- **実務での使い方**: 推論エンドポイントに対してModel Monitorを有効化し、学習時のベースラインデータ
- **副業での需要**: ★★★★☆(継続的に性能を維持する「運用フェーズ」のモニタリング設計は高単価案件

モデルドリフトの種類

- **概要**: 時間の経過とともにモデルの有効性が失われる主要な3つの要因。
- **試験ポイント**: データ品質（ライブデータの分布が学習時と異なる）、モデル品質（予測精度の低下）
- **実務での使い方**: ドリフトの種類を特定することで、「データの再収集・クレンジング」が必要か、「
- **副業での需要**: ★★★☆☆(ML運用(MLOps)における問題切り分けの基礎知識)

SageMaker Model Monitor

- **概要**: フルマネージドなモデル監視サービス。エンドポイントにデプロイされたモデルの品質を継続的に
- **試験ポイント**: データキャプチャ、ベースライン作成、スケジュール実行、分析結果のS3保存といった
  Monitorは「推論データの整合性維持」が目的。
- **実務での使い方**: 学習完了時に生成されるベースライン統計を元に、日次・週次で推論データの偏りを確
- **副業での需要**: ★★★★☆(MLOpsパイプライン自動化の実装において不可欠なスキル)

SageMaker Data Wrangler (視覚的なデータ前処理)

- **概要**: SageMaker Studio統合のGUIベース・データ前処理ツール。300以上の組み込み変換をノーコー
- **試験ポイント**: ローカル環境やEMR、SageMaker Processing Jobと比較して、構成労力が最小限（ドラ
  特に50MB程度の小規模データに対して、インフラ構築のオーバーヘッドなしに迅速に処理できる点が
- **実務での使い方**: 初期段階のデータ探索（EDA）やプロトタイプ作成に使用し、作成したデータフロー
  Pipelinesのステップとしてエクスポートして本番パイプラインへ統合する。
- **副業での需要**: ★★★★☆(迅速なPoC構築や、非専門家へのデータ共有・可視化において非常に重宝さ

SageMaker Pipelines (MLワークフローの統合管理)

- **概要**: 前処理、訓練、評価、登録、デプロイといった一連のMLステップを連結し、自動化されたワーク
- **試験ポイント**: SageMaker Studioとの統合によるワークフローの可視化。条件分岐（評価結果に基づく
- **実務での使い方**: モデルのライフサイクル全体をコード（Python SDK）で定義し、CI/CDパイプラインと連携して「継続的学習（Continuous Training）」を実現する基盤として活用する。
- **副業での需要**: ★★★★★(MLOpsの根幹となるサービスであり、商用レベルのシステム構築には必須)

データ前処理ツールの選定基準 (EMR vs Processing Job vs Data Wrangler)

- **概要**: データの規模、複雑さ、運用リソースに応じた最適な計算リソースの選択。
- **試験ポイント**: 大規模ETL（数TB〜）ならEMR/Spark、独自のカスタムロジックをコンテナで実行した
  Job、簡便性とスピード重視ならData Wranglerという対比。50MB程度のデータにEMRクラスターを走
- **実務での使い方**: データサイズだけでなく、チームのスキルセット（Sparkが使えるか等）や将来的なパ
- **副業での需要**: ★★★☆☆(コストパフォーマンスを最大化するアーキテクチャ提案能力)

Apache Parquet形式の活用

- **概要**: 高い圧縮率と優れたクエリパフォーマンスを両立する列指向（カラムナ）データ形式。機械学習
- **試験ポイント**: 大規模データセットの効率的な保存と高速な読み込み。Data Wrangler等のSageMakerツール群で直接サポートされており、前処理効率を大幅に向上させる点。
- **実務での使い方**: S3データレイク上の生データ（CSV/JSON等）をParquet形式に変換（Glue ETL等）して保存することで、学習ジョブのI/O待ち時間を短縮しコストを削減する。
- **副業での需要**: ★★★☆☆(データエンジニアリングのベストプラクティス知識)

SageMaker トレーニング手法の選定 (Script Mode vs Built-in vs Custom)

- **概要**: 既存資産（コード）や専門性に応じた最適なトレーニング環境の選択。
- **試験ポイント**: 既存のPyTorch/TensorFlowスクリプトを最小限の変更で移行したい場合の最適解は「ス
- **実務での使い方**: 基本は事前構築済みイメージのスクリプトモードを選択し、依存ライブラリが多い場
- **副業での需要**: ★★★★☆(既存モデルのAWS移行案件における工数見積もりと設計のキモとなる知識)

SageMaker スクリプトモード (Script Mode)

- **概要**: AWSが提供する、PyTorch、TensorFlow、Scikit-learnなどの主要フレームワーク用事前構築済み
- **試験ポイント**: インフラ（コンテナ）構築の手間を省きつつ、コードの自由度を最大限に確保できる点
トレーニングスクリプトをS3に配置してジョブを実行するワークフロー。
- **実務での使い方**: ローカルや検証環境で作成済みのモデルコードを、環境構築なしにSageMakerの強力
- **副業での需要**: ★★★★★(「手元のコードをそのままクラウドで動かしたい」というニーズへの最も迅

カスタムコンテナ vs 事前構築済みイメージ

- **概要**: 学習・推論環境のパッケージング手法の比較。
- **試験ポイント**: カスタムコンテナは自由度は高いが、イメージ作成・テスト・デプロイ、および継続的な
- **実務での使い方**: 独自のバイナリや古いライブラリ、特殊なシステム依存関係があるレガシーシステムの
- **副業での需要**: ★★★☆☆(保守性と開発速度のバランスが取れたシステム提案に不可欠)

AWS Marketplace と 組み込みアルゴリズムの制限

- **概要**: 汎用的なモデル・アルゴリズムを利用できるが、独自のドメイン知識（カスタムロジック）を必要
- **試験ポイント**: 既存資産（スクリプト）を活用する場合、これらはモデルを一から再構築する必要があ
- **実務での使い方**: 標準的なタスク（画像分類、時系列予測等）で独自のロジックが不要な場合に限り、
- **副業での需要**: ★★☆☆☆(専門性を出すならスクリプトモード以上が主流)

SageMaker 非同期推論 (Asynchronous Inference)

- **概要**: 大規模なペイロード（最大1GB）や長い推論時間（最大1時間）を必要とするリクエストをキュー
- **試験ポイント**: 唯一、インスタンス数を「0」にスケールダウンできる推論オプションであり、リクエス
推論結果はS3に保存され、SNS等で完了通知を受け取る仕組み。
- **実務での使い方**: 推論の即時性（レイテンシ）よりも、大きな画像や動画の着実な処理と、アイドリン
- **副業での需要**: ★★★★☆(コスト効率とスケーラビリティを重視する小〜中規模の開発案件で非常に喜

ローコード・ノーコード (LCNC) によるML構築

- **概要**: 最小限のコーディング（または完全なGUI操作）で、機械学習モデルの構築・デプロイを実現する
- **試験ポイント**: プログラミング専門知識が乏しいユーザー向け。SageMaker AutopilotやJumpStartがこのカテゴリに属し、EC2（マニュアル）やStudio（コードベース）は
- **実務での使い方**: 非技術職が迅速にPoC（概念実証）を行う際や、標準的な予測タスクを低コスト・短
- **副業での需要**: ★★★★☆(ツールの活用による開発期間の大幅短縮と、エンジニア以外のステークホル

SageMaker Autopilot (AutoML)

- **概要**: 構造化データに対して、前処理からモデル選択、ハイパーパラメータチューニングまでを自動化し
- **試験ポイント**: GUI操作のみで完結可能でありながら、生成されたプロセスがノートブックとして公開さ
- **実務での使い方**: 新しいデータセットに対して、まずはAutopilotを走らせて精度のベースラインを作成
- **副業での需要**: ★★★☆☆(効率的なモデル選定・チューニングプロセスの自動化に貢献)

SageMaker JumpStart

- **概要**: 事前学習済みモデル（LLM、画像、テキスト等）や業界別ソリューションテンプレートを、ワン
- **試験ポイント**: 自前のデータセットを用いたファインチューニングをサポートしている点。一から学習
- **実務での使い方**: 最新の基盤モデル（Llama等）を自社環境にセキュアに導入したい場合や、解きたい
- **副業での需要**: ★★★★★(生成AIの導入や、高度な訓練済みモデルを低コストかつ迅速に提供する案件

Amazon SageMaker Ground Truth (データラベリング)

- **概要**: 画像、テキスト、動画などの生データに対し、効率的かつ正確にメタデータ（ラベル）を付与す
- **試験ポイント**: 3種類のワークフォース（内部、サードパーティベンダー、Mechanical Turk）の使い分け。アクティブラーニング（自動ラベリング）機能により、人間がラベルを付けた一部
- **実務での使い方**: アノテーション作業の進捗管理や、作業者間のラベルの一貫性チェック、特定分野（
- **副業での需要**: ★★★★☆(高品質な学習データの作成はAI開発の最重要工程であり、効率的なラベリン

SageMaker Ground Truth ワークフォースの選定

- **概要**: ラベリングタスクを誰に割り当てるかの選択肢。
- **試験ポイント**: 「機密データや専門知識が必要」な場合は、自社で管理する**内部ワークフォース（Inter Workforce）**が最適。AWS Data Exchangeは「既存データセットの購入」用であり、ラベリングプロ TurkはGround Truth経由で利用することで、匿名性を保ちつつ大規模なラベリングを依頼できる。
- **実務での使い方**: セキュリティ要件（プライバシー保護）、予算、必要なスキルに応じてワークフォー
- **副業での需要**: ★★★☆☆(コンプライアンスを遵守したデータ処理パイプラインの設計能力)

SageMaker Augmented AI (A2I) vs Ground Truth

- **概要**: A2Iは「推論結果の人間によるレビュー」であり、Ground Truthは「学習データの作成（ラベリング）」であるという目的の違い。
- **試験ポイント**: 既にデプロイされたモデルの予測結果が特定のしきい値を下回った際に、人間が内容を in-the-loop）がA2I。一からモデルを訓練するための教師データを作るのがGround Truth。

- **実務での使い方**: 高い精度が求められる業務（例：コンテンツモデレーション、重要書類の分類）で、
- **副業での需要**: ★★★☆☆(AIシステムの信頼性を担保する実運用レベルのアーキテクチャ設計)

AWS Glue による機密データ検出とマスキング

- **概要**: Apache Sparkジョブ内で、クレジットカード番号や個人情報（PII）を自動検出し、マスキング処
- **試験ポイント**: 「機密データの検出だけでなく、マスキングまで一元的に行いたい」「開発・運用工数
  MacieはS3上のデータ検出・レポートには優れているが、マスキング（変換）機能を持たないため、E
- **実務での使い方**: データレイク（S3）から分析用環境へデータを転送する際、法規制（GDPR, PCI DSS等）に準拠するためにPIIを自動で匿名化するパイプラインを構築する。
- **副業での需要**: ★★★★☆(企業のデータガバナンス強化や、セキュアなデータ基盤構築案件において、

機密データ保護の選定基準 (Glue vs Macie vs Regex)

- **概要**: PII（個人を特定できる情報）の保護手法の比較。
- **試験ポイント**: 正規表現（Regex）による独自実装は、多種多様なパターン（国際的なクレカ番号等）の
- **実務での使い方**: 基本はGlueの標準機能で対応し、業界独自の特殊なID体系などの場合にのみ正規表現
- **副業での需要**: ★★★☆☆(コスト、保守性、セキュリティ強度のバランスを考慮したアーキテクチャ提

ETL基盤の運用設計 (Glue vs EC2/Custom Spark)

- **概要**: サーバーレスETL（Glue）とセルフマネージド（EC2+Spark）の比較。
- **試験ポイント**: EC2環境ではOSのパッチ適用、Sparkのクラスター管理、スケーリング設定などの運用
- **実務での使い方**: 独自の複雑なライブラリ依存がある場合を除き、GlueやGlue Studioを活用してビジュアルまたは簡易なスクリプトでパイプラインを構築・維持する。
- **副業での需要**: ★★★☆☆(「動くもの」だけでなく「運用し続けられるもの」を納品するための設計ス

SageMaker 訓練ジョブのデータ読み込みモード (File vs Fast File)

- **概要**: S3から訓練環境へデータをロードする際の手法。
- **試験ポイント**: **Fast File mode**はS3オブジェクトをローカルファイルシステムとして仮想的にマウント
  mode（ファイルを全てダウンロードしてから開始）の弱点である「起動待ち時間」を劇的に短縮でき
- **実務での使い方**: 大規模なデータセット（特に多数の小さな画像ファイル等）を扱う際、ジョブの開始
- **副業での需要**: ★★★★☆(効率的なトレーニングパイプライン設計による開発サイクル高速化の提案)

SageMaker におけるストレージ選択 (EFS vs FSx for Lustre)

- **概要**: 訓練データの配置先と、それによるパフォーマンス・コストの使い分け。
- **試験ポイント**: **FSx for Lustre**はHPCワークロード向けで超高スループットを実現するが、プロビジョ
  (+ Fast File mode) が最も安価。
- **実務での使い方**: データの繰り返し読み込みが頻繁な大規模分散学習にはFSx、複数の実験ジョブで同じ
- **副業での需要**: ★★★☆☆(インフラ費用を抑えつつ、学習効率を最大化する「賢い」ストレージ選定能

S3 Express One Zone の活用基準

- **概要**: 単一のアベイラビリティーゾーン内で、標準S3よりも10倍低いレイテンシと高いスループットを提
- **試験ポイント**: 非常に頻繁にアクセスされるデータ（何千回もの繰り返し読み込み等）には適している
  Standard + Fast File modeの方が圧倒的に有利であるという判断。
- **実務での使い方**: 超高速なチェックポイント保存や、非常にステップ数の多い反復学習において、I/Oが
- **副業での需要**: ★★☆☆☆(特定のハイパフォーマンス要件に対するピンポイントな最適化知識)

SageMaker Linear Learner (線形学習器)

- **概要**: 二値分類、多クラス分類、回帰タスクに対応する、特徴量の重み付けによる線形モデル。
- **試験ポイント**: 最大の特徴は高い**解釈性（Explainability）**。各特徴量の重みを直接確認できるため、
- **実務での使い方**: 複雑な非線形モデルを検討する前のベースライン作成や、金融機関の融資審査など「な
- **副業での需要**: ★★★☆☆(高い信頼性と規制遵守が求められるエンタープライズ系案件での堅実な選択

機械学習モデルの説明可能性 (Explainability)

- **概要**: 予測結果の理由を人間が理解できる性質。
- **試験ポイント**: 線形モデルや決定木は「本質的に説明可能（Inherently Explainable）」だが、深層学習（ニューラルネットワーク）は「ブラックボックス」になりやすいと
  金融・医療・公共セクターなど、判断根拠の説明が法的に求められる分野での重要性。
- **実務での使い方**: 性能（精度）だけを追わず、運用面での「説明コスト」を考慮して、あえて単純なモデ
- **副業での需要**: ★★★★☆(コンプライアンスや倫理的AIの設計は付加価値が高く、コンサルティング領

SageMaker 組み込みアルゴリズムの選定基準

- **概要**: AWSが提供・最適化した高パフォーマンスなアルゴリズム群（XGBoost, k-means, Object2Vec等）。
- **試験ポイント**: **カスタムコンテナの構築が不要**であり、迅速な開発・デプロイが可能。各アルゴリズム
- **実務での使い方**: ゼロからの自作を避け、まずは組み込みアルゴリズムのパラメータチューニングで要件
- **副業での需要**: ★★★☆☆(「素早く正確に」PoCを回すことが求められる案件での必須知識)

SageMaker カスタムコンテナと Amazon ECR

- **概要**: 独自のDockerイメージを構築し、Amazon ECR(Elastic Container Registry)経由でSageMakerから利用する手法。
- **試験ポイント**: 標準コンテナにない特定のライブラリやバージョン、独自のバイナリが必要な場合の最適
- **実務での使い方**: 企業独自のセキュリティポリシーやライブラリ要件があるプロジェクトにおいて、再現
- **副業での需要**: ★★★★☆ (コンテナ技術を駆使した高度なMLOps基盤の設計・構築案件で重宝される専門性)

実行環境の適切な選択 (Notebook vs Jobs vs EC2)

- **概要**: 開発段階（試作）と本番運用段階（自動化）における最適な計算リソースの使い分け。
- **試験ポイント**: **ノートブックインスタンス**はJupyter実行用のマネージド環境であり、対話型の開発や可
- **実務での使い方**: ノートブックでEDAや試作を行い、完成した学習・推論ロジックは速やかにコンテナ

- **副業での需要**: ★★★☆☆(「ただ動くコード」ではなく「運用を考慮した効率的なシステム」を提案す

Amazon Bedrock Knowledge Base (RAGの自動化)

- **概要**: S3等のデータソースを自動でインデックス化・ベクトル化し、LLMに最新のコンテキストを提供
- **試験ポイント**: **「最小の運用負荷」でRAGを実装したい**場合の決定打。インフラ管理、スケーリング、Aurora等）との統合、セキュリティパッチ適用がすべてマネージド。SageMakerでの自作と比較して圧
- **実務での使い方**: 自社のマニュアルや専門文書をS3に置くだけで、回答性能の高いAIエージェントを迅
- **副業での需要**: ★★★★★(生成AI活用の最重要コンポーネントであり、導入実績が強く求められる分野

RAG実装におけるサービス選定基準

- **概要**: 運用コスト、開発期間、柔軟性のトレードオフに基づくアーキテクチャ選定。
- **試験ポイント**: SageMaker Pipelines/AutoMLは訓練・推論管理に優れるが、RAG専用のベクトル検索基Knowledge Baseはこれらを一つのサービスで完結させる「Low-Ops」な選択肢である点。
- **実務での使い方**: 特殊な埋め込みモデルの自作や、極端に複雑なカスタムリランク処理が必要な場合を除Knowledge Baseで「工数対効果」を最大化する。
- **副業での需要**: ★★★★☆(顧客の予算とスピード感に合わせた「賢い」AWSサービスの組み合わせ提案

SageMaker Experiments (実験管理)

- **概要**: 機械学習モデルの訓練反復（異なるパラメータ、データ、アルゴリズム）を体系的に追跡・比較す
- **試験ポイント**: **SageMaker Trainingジョブとネイティブ統合**されており、「実験 > 試行 > 試行コンポーネント」の階層構造で数百の反復を整理できる。可視化ダッシュボードにより、
- **実務での使い方**: 試行錯誤の多い探索的データ分析やハイパーパラメータチューニングのフェーズで導入
- **副業での需要**: ★★★☆☆(実験の再現性と組織化は、プロジェクトの持続可能性を高めるプロの仕事と

機械学習の実験管理手法の比較

- **概要**: 監視ツール（CloudWatch）やログ分析（S3/Athena）、モデル管理（Registry）との役割の違い
- **試験ポイント**: CloudWatchは「リアルタイム監視」であり、数百の試行差分を比較・階層化する機能は Registryは「本番デプロイの承認」用。**実験過程の追跡には専用のSageMaker Experimentsを使うのが最も効率的**。
- **実務での使い方**: 用途に応じてサービスを使い分ける設計を採る（実験：Experiments、承認：Registry
- **副業での需要**: ★★★★☆(AWSのMLスタックを「適材適所」で使いこなし、開発工数を削減するエン

Amazon Comprehend DetectPiiEntities (PII検出の自動化)

- **概要**: テキストデータから氏名、メール、住所、クレカ番号等の個人情報を自動識別するマネージドAP
- **試験ポイント**: **「テキストデータ内の個人情報を削除・マスキングしてモデル学習に使いたい」**という要 Macie（監査用で自動削除なし）やGlue DataBrew（視覚的変換だがPII特化ではない）よりも精度と開
- **実務での使い方**: コールセンターの対応履歴やSNSの投稿データを学習データとして安全に利用するため
- **副業での需要**: ★★★★☆(データの二次利用やLLMのファインチューニングにおけるプライバシー保護

SageMaker における S3 vs EFS の運用効率

- **概要**: 訓練データへのアクセス手法の比較。
- **試験ポイント**: 単一のSageMakerインスタンスからアクセスする場合、S3は**セットアップ不要・管理負**
  EFSはマウント設定（NFS）やVPC構成が必要なため、管理オーバーヘッドが大きく、単一インスタン
- **実務での使い方**: 基本はS3を標準とし、複数のノードで大規模な共通データセットを共有し続ける必要
- **副業での需要**: ★★★☆☆(インフラ構築の「引き算」による、迅速な価値提供とコスト・運用負荷の削

PII保護サービスの選定基準 (Comprehend vs Macie vs DataBrew)

- **概要**: データの保存場所や用途に応じた最適なセキュリティツールの選択。
- **試験ポイント**: MacieはS3内の機密データを「監視・警告（レポート）」する監査用で、データの自動
  DataBrewは「クレンジング・正規化」などの一般的な加工用ツール.
  「学習用データそのものを加工したい」場合はComprehend APIが最適。
- **実務での使い方**: セキュリティ担当向けの全体監視にはMacie、開発パイプライン内での自動匿名化に
- **副業での需要**: ★★★☆☆(AWSの豊富なセキュリティ・ツール群の「正解」を提示できるコンサルティ